

Carrera: Ingeniería Informática | Materia: Data Science

PROYECTO INTEGRADOR DE CIENCIA DE DATOS

Documento de comprensión del problema

Asociación entre cobertura de seguro médico y enfermedad reciente
en Paraguay: análisis de la EPHC 2024

Grupo 4

Kyara Ivanna Popov Araujo C.I. 5403389

Zinri Alice Bobadilla Peralta C.I. 5306066

Alejandro Sanabria Penayo C.I. 5689736

Asunción, 19 de septiembre de 2026

1. Contexto del problema

La Encuesta Permanente de Hogares Continua (EPHC), elaborada por el Instituto Nacional de Estadística (INE) del Paraguay, releva información demográfica, social, laboral y de salud de la población residente en hogares particulares. Entre sus variables se encuentran la cobertura de seguro médico y el estado de salud reportado durante los últimos 90 días, además de características demográficas y socioeconómicas que permiten contextualizar diferencias entre grupos de población.

La cobertura de seguro médico constituye una dimensión relevante del acceso al sistema de salud. Sin embargo, poseer o no cobertura puede estar relacionado con otras características de las personas, como edad, nivel educativo, ingreso, sexo o área de residencia. Por ello, el proyecto se orienta a describir y evaluar la asociación entre cobertura y enfermedad reciente sin interpretar las diferencias observadas como relaciones causales.

2. Pregunta de investigación

¿La proporción de personas que reportaron enfermedad en los últimos 90 días difiere entre quienes poseen y quienes no poseen cobertura de seguro médico en Paraguay, según la EPHC 2024?

3. Objetivo general

Analizar la asociación entre la cobertura de seguro médico y la ocurrencia de enfermedad reportada en los últimos 90 días en la población representada por la EPHC 2024.

4. Objetivos específicos

- Preparar y caracterizar las variables relevantes de la EPHC 2024, evaluando su calidad, consistencia, valores faltantes y necesidad de recodificación.
- Describir y comparar la ocurrencia de enfermedad reportada en los últimos 90 días entre personas con y sin cobertura de seguro médico, mediante estadísticas descriptivas y visualizaciones.
- Evaluar estadísticamente la asociación entre la cobertura de seguro médico y la ocurrencia de enfermedad reciente, mediante técnicas de inferencia adecuadas a las características de los datos.
- Construir y evaluar un modelo predictivo de enfermedad reciente utilizando la cobertura de seguro médico y otras variables disponibles y pertinentes de la EPHC 2024.
- Interpretar los resultados descriptivos, inferenciales y predictivos, identificando patrones, limitaciones y posibles implicancias de los hallazgos.

5. Justificación de la relevancia

Responder esta pregunta permite caracterizar si existen diferencias observables en el reporte de enfermedad reciente entre personas con y sin cobertura médica. El resultado puede aportar evidencia descriptiva sobre la relación entre cobertura y condiciones de salud autorreportadas, además de ayudar a identificar variables demográficas y socioeconómicas que deban considerarse en análisis posteriores.

Desde el punto de vista académico, el problema permite desarrollar de manera integrada las tres fases del proyecto: en la Fase 1 se describen y exploran los datos; en la Fase 2 se contrastarán formalmente hipótesis estadísticas; y en la Fase 3 se evaluará la capacidad predictiva de la cobertura y otras características para anticipar la ocurrencia de enfermedad reciente. La respuesta puede ser útil para comprender patrones poblacionales, siempre dentro de las limitaciones de una encuesta observacional.

6. Alcance

El análisis principal se limita a personas de la EPHC Anual 2024 con respuestas válidas en la variable de salud de los últimos 90 días. Se compara la condición Enfermo/a frente a Sano/a. Los registros clasificados como Accidentado/a se excluyen del dataset analítico principal porque representan un evento distinto de la enfermedad estudiada. Asimismo, se excluyen códigos no contemplados como respuestas válidas.

La cobertura médica se resume mediante una variable binaria construida a partir de S01A: con seguro para las categorías de cobertura informadas y sin seguro para el código correspondiente. Los resultados ponderados utilizan el factor de expansión cuando se pretende representar a la población, mientras que otros análisis describen la muestra observada. La dimensión temporal se complementa con los REG02 trimestrales oficiales de 2024 únicamente como contexto, dado que esos archivos no contienen las variables S01A y S03.

7. Limitaciones previstas

- El diseño de la EPHC es observacional, por lo que las asociaciones encontradas no permiten establecer causalidad.
- La enfermedad es autorreportada y puede estar sujeta a diferencias de percepción, recuerdo o acceso al diagnóstico.
- Las personas con y sin seguro pueden diferir en edad, educación, ingreso, sexo, área y otras características que deben considerarse al interpretar la comparación simple.
- Las variables socioeconómicas presentan algunos valores faltantes; en la Fase 1 no se imputan sin estudiar previamente su mecanismo de ausencia.
- El análisis predictivo futuro dependerá de la calidad y disponibilidad de las variables seleccionadas y deberá evitar fuga de información durante el preprocesamiento.

8. Fuente de datos

Instituto Nacional de Estadística (INE Paraguay), Encuesta Permanente de Hogares Continua (EPHC) 2024. Base principal: REG02 EPHC Anual 2024. Portal oficial de microdatos: <https://www.ine.gov.py/microdato/>