

Carrera: Ingeniería Informática | Materia: Data Science

PROYECTO INTEGRADOR DE CIENCIA DE DATOS

Fase 1 — Comprensión, preparación y análisis exploratorio

Asociación entre cobertura de seguro médico y enfermedad reciente
en Paraguay: análisis de la EPHC 2024

Grupo 4

Kyara Ivanna Popov Araujo C.I. 5403389

Zinri Alice Bobadilla Peralta C.I. 5306066

Alejandro Sanabria Penayo C.I. 5689736

Asunción, 19 de septiembre de 2026

Índice

1. Comprensión del problema	2
1.1 Contexto	2
1.2 Pregunta de investigación	2
1.3 Objetivo general	2
1.4 Objetivos específicos	2
1.5 Alcance y limitaciones	2
2. Comprensión y selección de datos	2
2.1 Diccionario de datos (dataset analítico limpio)	3
3. Limpieza y transformación	4
3.1 Bitácora de limpieza	4
4. Análisis univariado y bivariado	6
4.1 Variables numéricas	6
4.1.1 Variables categóricas	7
4.2 Comparación principal: seguro y enfermedad	7
4.3 Relaciones adicionales	8
5. Análisis descriptivo y exploratorio	11
5.1 Dimensión temporal	12
5.2 Hipótesis preliminares para Fase 2	13
6. Conclusión de la Fase 1	13
7. Integridad académica y uso de asistentes de IA	13
Referencias y fuente	14

1. Comprensión del problema

1.1 Contexto

La Encuesta Permanente de Hogares Continua (EPHC), elaborada por el Instituto Nacional de Estadística del Paraguay, releva información demográfica, social, laboral y de salud de la población residente en hogares particulares. Dentro de la sección de salud se consulta si las personas poseen cobertura de seguro médico y si durante los últimos 90 días estuvieron enfermas, accidentadas o sanas. Estas variables permiten estudiar descriptivamente diferencias en el reporte de enfermedad reciente según cobertura médica.

1.2 Pregunta de investigación

¿La proporción de personas que reportaron enfermedad en los últimos 90 días difiere entre quienes poseen y quienes no poseen cobertura de seguro médico en Paraguay, según la EPHC 2024?

1.3 Objetivo general

Analizar la asociación entre la cobertura de seguro médico y la ocurrencia de enfermedad reportada en los últimos 90 días en la población representada por la EPHC 2024.

1.4 Objetivos específicos

- Preparar y caracterizar las variables relevantes de la EPHC 2024, evaluando su calidad, consistencia, valores faltantes y necesidad de recodificación.
- Describir y comparar la ocurrencia de enfermedad reportada en los últimos 90 días entre personas con y sin cobertura de seguro médico, mediante estadísticas descriptivas y visualizaciones.
- Evaluar estadísticamente la asociación entre la cobertura de seguro médico y la ocurrencia de enfermedad reciente mediante técnicas de inferencia adecuadas.
- Construir y evaluar un modelo predictivo de enfermedad reciente utilizando cobertura de seguro médico y otras variables pertinentes.
- Interpretar los resultados descriptivos, inferenciales y predictivos, identificando patrones, limitaciones y posibles implicancias.

1.5 Alcance y limitaciones

El trabajo analiza asociaciones y no causalidad. La enfermedad es autorreportada. Los accidentes se excluyen del dataset analítico principal porque representan un evento distinto de la enfermedad. Los resultados ponderados se presentan cuando se pretende representar población, mientras que algunos análisis exploratorios describen la muestra observada. Las variables socioeconómicas faltantes no se imputan en esta fase.

2. Comprensión y selección de datos

La base principal es REG02 de la EPHC Anual 2024. La versión oficial suministrada contiene 57.744 registros y 213 variables. La unidad de análisis es cada persona integrante de un hogar encuestado. La clave compuesta UPM + NVIVI + NHOGA + L02 fue verificada empíricamente y resultó única para los 57.744 registros.

Se seleccionaron 16 variables originales relacionadas con trazabilidad, geografía, demografía, seguro médico, estado de salud, ponderación y dimensión socioeconómica: UPM, NVIVI, NHOGA, L02, AÑO, DPTO, AREA, P02, P06, P09, S01A, S03, FACTOR, añoest, ipcm y quintili. La columna FACTOR corresponde a la versión oficial suministrada (Factor Revisión 2025) y se normalizó como factor_expansion.

La fuente oficial es el Instituto Nacional de Estadística. El diccionario oficial se conserva junto al proyecto y el diccionario elaborado por el grupo incluye descripción, tipo, escala, unidad, rango/categorías observadas y porcentaje de faltantes.

2.1 Diccionario de datos (dataset analítico limpio)

El siguiente diccionario describe las 25 variables del dataset final `ephc_salud_2024_limpio.csv` (57.109 registros), reconstruido a partir del código de limpieza y verificado directamente contra los datos exportados.

Campo	Descripción	Tipo	Unidad / escala	Rango o categorías observadas	% falt.
persona_id	Identificador único de persona (UPM-NVIVI-NHOGA-L02)	Texto (clave)	—	57.109 valores únicos	0,00%
UPM	Unidad primaria de muestreo	Entero	Código INE	14 – 28.774	0,00%
NVIVI	Número de vivienda dentro de la UPM	Entero	Código	1 – 975	0,00%
NHOGA	Número de hogar dentro de la vivienda	Entero	Código	1 – 3	0,00%
L02	Número de línea de la persona en el hogar	Entero	Código	1 – 27	0,00%
año	Año de la encuesta	Entero	Año	2024 (constante)	0,00%
departamento_codigo	Código de departamento de residencia (DPTO)	Entero	Código INE	0 – 15 (16 categorías)	0,00%
departamento	Nombre del departamento de residencia	Categórica	—	16 categorías (Central, Alto Paraná, Asunción, ...)	0,00%
area_codigo	Código de área de residencia (AREA)	Entero	Código	1, 6	0,00%
area	Área de residencia	Categórica	—	Urbana, Rural	0,00%
edad	Edad de la persona	Entero	Años	0 – 106	0,00%
sexo_codigo	Código de sexo (P06)	Entero	Código	1, 6	0,00%
sexo	Sexo	Categórica	—	Hombre, Mujer	0,00%
estado_civil_codigo	Código de estado civil (P09)	Entero	Código	1 – 6	0,00%
estado_civil	Estado civil	Categórica	—	6 categorías (Soltero/a, Casado/a, ...)	0,00%
seguro_codigo	Código de cobertura de seguro médico (S01A)	Entero	Código	1 – 7	0,00%
tipo_seguro	Tipo de cobertura de seguro médico	Categórica	—	7 categorías (Sin seguro, IPS, Seguro privado familiar, Seguro privado laboral, Sanidad Policial, Sanidad Militar, Seguro privado individual)	0,00%

Campo	Descripción	Tipo	Unidad / escala	Rango o categorías observadas	% falt.
tiene_seguro	Indicador binario de cobertura de seguro	Entero (0/1)	Binaria	0 = sin seguro, 1 = con seguro	0,00%
salud_90d_codigo	Código de estado de salud en últimos 90 días (S03, ya filtrado)	Entero	Código	1, 3	0,00%
estado_salud_90d	Estado de salud reportado en últimos 90 días	Categorica	—	Enfermo/a, Sano/a	0,00%
enfermedad_reciente	Indicador binario de enfermedad reciente	Entero (0/1)	Binaria	0 = sano/a, 1 = enfermo/a	0,00%
factor_expansion	Factor de expansión muestral (FACTOR, Revisión 2025)	Decimal	Factor	10,26 – 889,47	0,00%
anios_estudio	Años de estudio aprobados (añoest; código 99 recodificado a NaN)	Entero	Años	0 – 18	6,20%
ingreso_per_capita_mensual	Ingreso per cápita mensual del hogar (ipcm)	Decimal	Guaraníes	0 – 146.786.737	0,23%
quintil_ingreso	Quintil de ingreso per cápita (quintili)	Entero	Quintil	1 – 5	0,23%

*Nota de corrección: en una versión previa de este diccionario, **seguro_codigo** figuraba con “rango 1-8”. Se corrige a 1-7, que es el rango real de la variable S01A en la EPHC 2024 (1=IPS, 2=Seguro privado individual, 3=Seguro privado laboral, 4=Seguro privado familiar, 5=Sanidad Militar, 6=Sanidad Policial, 7=Sin seguro). El código 8 no existe en el diccionario oficial ni en los datos; su inclusión en un mapeo auxiliar del notebook no afectó ningún resultado, porque ese código nunca aparece en la muestra.*

3. Limpieza y transformación

La limpieza se definió de manera reproducible por código. Los campos de texto vacíos se normalizaron a NaN. El factor de expansión y el ingreso per cápita se convirtieron a valores numéricos. El código 99 de años de estudio se recodificó como faltante porque no representa una cantidad real de años.

Para la variable S03 se conservan como análisis principal únicamente Enfermo/a (1) y Sano/a (3). Se excluyeron 631 registros de personas accidentadas (S03=2) y 4 registros con código 9 no válido. El resultado es un dataset analítico de 57.109 personas y 25 variables. No se eliminaron valores extremos por el solo hecho de ser extremos.

Se creó `tiene_seguro`, codificada como 1 para S01A en 1-6 y 0 para S01A=7. También se creó `enfermedad_reciente`, con 1 para enfermedad y 0 para sano/a. La segunda cobertura S01B fue auditada y no se detectaron personas codificadas sin seguro en S01A con una segunda cobertura informada.

3.1 Bitácora de limpieza

Paso	Decisión / transformación aplicada	Registros afectados	Fundamento
1	Selección de las 16 variables originales y normalización de campos de texto vacíos a NaN	57.744 registros (base completa)	Estandarizar valores faltantes antes de cualquier cálculo posterior
2	Conversión de factor_expansion e ingreso_per_capita_mensual (separador decimal coma) a tipo numérico	57.744 registros	Los campos venían como texto con coma decimal en el archivo fuente
3	Recodificación de anios_estudio: código 99 -> NaN	Incluidos en el 6,20% de faltantes final de anios_estudio	El código 99 no representa una cantidad real de años de estudio
4	Mapeo de códigos numéricos a etiquetas legibles: departamento, área, sexo, estado civil, tipo de seguro y estado de salud	57.744 registros	Facilitar la lectura e interpretación en el análisis descriptivo
5	Construcción de persona_id como clave única (UPM-NVIVI-NHOGA-L02)	57.744 registros	Se verificó empíricamente su unicidad para los 57.744 registros
6	Creación de tiene_seguro (1 si S01A toma códigos 1-6 ; 0 si S01A=7, “Sin seguro”) y de enfermedad_reciente (1 si S03=1 “Enfermo/a”; 0 si S03=3 “Sano/a”)	57.744 registros	S01A solo toma valores de 1 a 7 en la EPHC 2024 (no existe la categoría 8); el código 7 identifica explícitamente “Sin seguro”, por lo que queda en 0
7	Exclusión de accidentados (S03=2) y de código no válido (S03=9) del dataset analítico principal	631 + 4 = 635 registros excluidos	Un accidente es un evento distinto de la enfermedad reciente estudiada; el código 9 no es una respuesta válida

Paso	Decisión / transformación aplicada	Registros afectados	Fundamento
8	Decisión de no imputar años_estudio, ingreso_per_capita_mensual ni quintil_ingreso en esta fase	3.543 / 130 / 130 registros con faltantes, respectivamente	Evitar sesgo sin antes estudiar el mecanismo de ausencia; la estrategia de imputación se definirá en el pipeline de modelado
9	Renombrado de columnas y exportación del dataset limpio a ephc_salud_2024_limpio.csv	57.109 registros x 25 variables	Transformación reproducible por código, sin edición manual de los datos

Nota de corrección: en una versión previa, el paso 6 de esta bitácora indicaba “códigos 1-6 y 8 de S01A”. Se corrige a “códigos 1-6”, ya que el código 7 (“Sin seguro”) ya queda correctamente en 0 tanto en el código del notebook como en el resto del informe; el código 8 no existe en la variable S01A.

4. Análisis univariado y bivariado

4.1 Variables numéricas

Variable	Media	Mediana	Moda	Desv. est.	CV (%)	IQR
Edad	32.95	30.00	10.00	21.92	66.53	35.00
Años de estudio	8.17	8.00	12.00	5.03	61.62	8.00
Ingreso per cápita	1,979,470	1,357,054	999,251	2,683,408	135.56	1,483,912

Variable	Mín.	Máx.	P5	P25	P50	P75	P95
Edad	0.00	106.00	3.00	14.00	30.00	49.00	72.00
Años de estudio	0.00	18.00	0.00	4.00	8.00	12.00	16.00
Ingreso per cápita	0	146,786,737	373,384	807,500	1,357,054	2,291,412	5,213,534

Forma de las distribuciones: edad (asimetría 0,46; curtosis -0,69), años de estudio (0,09; -1,04) e ingreso per cápita (11,19; 282,31). En edad, media y mediana son cercanas; en años de estudio la distribución es aproximadamente simétrica pero discreta; en ingreso la mediana y los percentiles son preferibles por la fuerte asimetría.

El ingreso per cápita presenta una fuerte asimetría positiva; por ello, la mediana y los percentiles son más representativos del ingreso típico que la media. La edad muestra asimetría positiva leve y los años de estudio presentan una distribución más equilibrada, aunque discreta.

4.1.1 Variables categóricas

Las variables categóricas se describieron mediante frecuencias absolutas y relativas. Como medida simple de concentración se calculó qué proporción acumulan las categorías más frecuentes equivalentes al 20% de las categorías observadas (redondeando hacia arriba).

Variable	N.º categorías	Más frecuente	% principal	Concentración top 20%
Cobertura	2	Sin seguro	73.53%	73.53%
Estado de salud	2	Sano/a	69.95%	69.95%
Tipo de seguro	7	Sin seguro	73.53%	93.25%
Sexo	2	Mujer	50.62%	50.62%
Área	2	Urbana	57.66%	57.66%
Departamento	16	Central	17.51%	45.07%
Estado civil	6	Soltero/a	52.18%	74.59%
Quintil	5	1.0	22.05%	22.05%

Destaca la concentración del tipo de seguro: las dos categorías más frecuentes (Sin seguro e IPS) reúnen 93,25% de los registros. En departamentos, las cuatro categorías más frecuentes acumulan 45,07%.

4.2 Comparación principal: seguro y enfermedad

Cobertura	Sanos	Enfermos	Enfermedad ponderada (%)
Sin seguro	29211	12780	29.30
Con seguro	10736	4382	27.99

La prevalencia ponderada de enfermedad reciente es 29,30% entre personas sin seguro y 27,99% entre personas con seguro. La diferencia descriptiva es de 1,31 puntos porcentuales. Este resultado todavía no permite afirmar significancia estadística ni causalidad.

Para la relación categórica-categórica se elaboraron tablas de contingencia con frecuencias absolutas, porcentajes por fila y por columna, además de estimaciones ponderadas cuando el objetivo era representar población. Para numérica-categórica se compararon estadísticos por grupo y diagramas de caja; para numérica-numérica se utilizaron diagramas de dispersión y correlaciones de Pearson y Spearman.




Figura 1: Prevalencia ponderada de enfermedad reciente según cobertura.




Figura 2: Distribución de la edad.

4.3 Relaciones adicionales

Las personas con seguro presentan una mediana de edad de 35 años, 12 años de estudio y un ingreso per cápita mensual cercano a 2,32 millones de guaraníes. Entre quienes no tienen seguro, las medianas son 28 años, 6 años de estudio y aproximadamente 1,12 millones de guaraníes. Estas diferencias muestran que la cobertura está asociada a otras características sociodemográficas que




Figura 3: Edad según enfermedad reciente.




Figura 4: Ingreso per cápita según cobertura.

deben considerarse en fases posteriores.

Las correlaciones lineales son bajas. La relación más marcada se observa entre años de estudio e ingreso per cápita: Pearson $\approx 0,26$ y Spearman $\approx 0,39$. La mayor magnitud de Spearman es coherente con la asimetría del ingreso.




Figura 5: Edad e ingreso según enfermedad reciente.




Figura 6: Mapa de calor de correlaciones de Spearman.

5. Análisis descriptivo y exploratorio

El EDA integra los resultados anteriores para identificar patrones que orienten la formulación de hipótesis. La cobertura de seguro no aparece aislada: se relaciona con variables demográficas y socioeconómicas que pueden modificar la comparación simple entre asegurados y no asegurados.




Figura 7: Distribución de tipos de seguro.




Figura 8: Enfermedad reciente según quintil de ingreso.

Se identifican al menos seis patrones relevantes: (1) diferencia pequeña de prevalencia por cobertura; (2) perfiles socioeconómicos distintos entre asegurados y no asegurados; (3) menor prevalencia descriptiva hacia el quintil de ingreso más alto; (4) fuerte asimetría y valores extremos del ingreso; (5) diferencias descriptivas por sexo y área; y (6) estabilidad de la composición urbana/rural a lo largo de 2024.




Figura 9: Enfermedad reciente por sexo y área.

5.1 Dimensión temporal

La base anual no incluye trimestre ni fecha de entrevista. Para completar la dimensión temporal se utilizaron los cuatro REG02 trimestrales oficiales de 2024. Estos archivos no contienen S01A ni S03, por lo que no permiten construir una prevalencia trimestral de seguro o enfermedad sin recurrir a datos inexistentes. Se utilizó AREA como variable temporal contextual, ya que está disponible en los cuatro trimestres y también forma parte del análisis principal. La proporción urbana ponderada se mantiene estable, pasando de 70,93% en T1 a 71,25% en T4; la proporción rural disminuye de 29,07% a 28,75%. No se observan quiebres temporales relevantes.




Figura 10: Composición ponderada urbana/rural por trimestre, EPHC 2024.

5.2 Hipótesis preliminares para Fase 2

1. La proporción de enfermedad reciente difiere entre personas con y sin cobertura de seguro médico.
2. La distribución de la edad difiere entre personas enfermas y sanas.
3. La ocurrencia de enfermedad reciente no se distribuye de la misma manera entre quintiles de ingreso.
4. Existe asociación positiva entre años de estudio e ingreso per cápita mensual.
5. La proporción de enfermedad reciente difiere entre área urbana y rural.

6. Conclusión de la Fase 1

El análisis descriptivo permite responder parcialmente la pregunta de investigación. En los datos observados, las personas sin seguro presentan una prevalencia ponderada de enfermedad reciente de 29,30%, frente a 27,99% entre quienes poseen cobertura. La diferencia es reducida, de aproximadamente 1,31 puntos porcentuales, y no puede interpretarse todavía como evidencia estadísticamente significativa ni causal.

La comparación simple debe leerse junto con otros hallazgos: los asegurados presentan mayores medianas de edad, educación e ingreso, y la enfermedad también muestra variaciones descriptivas por sexo, área y quintil de ingreso. Por tanto, las fases siguientes deberán evaluar si el patrón principal se mantiene al considerar otras variables relevantes.

Entre las limitaciones se encuentran el carácter observacional de la EPHC, el autorreporte de enfermedad, la presencia de faltantes socioeconómicos y la imposibilidad de inferir causalidad. La exclusión de accidentes fue deliberada para mantener coherencia con el fenómeno de enfermedad reciente estudiado. En la dimensión temporal, los REG02 trimestrales disponibles no contienen S01A ni S03, por lo que la serie se limita a una variable contextual común a los cuatro trimestres.

La Fase 1 deja preparado el conjunto analítico, el diccionario, la bitácora, el análisis descriptivo y exploratorio, la serie temporal contextual, las hipótesis preliminares y el código reproducible necesario para continuar con inferencia estadística y modelado predictivo.

7. Integridad académica y uso de asistentes de IA

El presente trabajo fue producido por los integrantes del Grupo 4. Se utilizó un asistente de inteligencia artificial (Claude, de Anthropic) como herramienta de apoyo durante el desarrollo de la Fase 1, específicamente para las siguientes tareas puntuales:

- **Depuración de código Python** durante la etapa de limpieza y transformación de datos (Etapa 3 del notebook).
- **Consulta de sintaxis** de las librerías utilizadas (pandas, numpy, matplotlib, seaborn).
- **Corrección de redacción** y de estilo del texto del informe.

Todo el código y el texto incorporado con ayuda del asistente fue revisado y comprendido por el grupo antes de su inclusión en el trabajo. Las decisiones metodológicas – selección de variables, criterios de limpieza y exclusión, elección de estadísticos y de visualizaciones – y la interpretación de los resultados fueron realizadas por los integrantes del grupo, quienes pueden responder sobre cualquier parte del proyecto durante la presentación final.

Referencias y fuente

Instituto Nacional de Estadística (INE Paraguay). Encuesta Permanente de Hogares Continua (EPHC) 2024. Dataset anual utilizado en el trabajo: versión oficial suministrada con FACTOR (Factor Revisión 2025). Para la dimensión temporal se utilizaron los REG02 trimestrales oficiales de 2024. Portal de microdatos: <https://www.ine.gov.py/microdato/>

Universidad – Facultad de Ingeniería. Proyecto Integrador de Ciencia de Datos: del problema de negocio al modelo predictivo, desarrollo en tres fases.

Materiales de clase de Ciencia de Datos: análisis descriptivo, representación de datos, estadística, limpieza y transformación.