PROYECTO INTEGRADOR DE CIENCIA DE DATOS

Fase 2: Análisis inferencial

Asociación entre cobertura de seguro médico y enfermedad reciente en Paraguay: análisis de la EPHC 2024

Carrera: Ingeniería Informática | Materia: Data Science

Grupo 4

Kyara Ivanna Popov Araujo, C.I. 5403389

Zinri Alice Bobadilla Peralta, C.I. 5306066

Alejandro Sanabria Penayo, C.I. 5689736

Asunción, 10 de octubre de 2026

Contenido

Índice ..... **¡Error! Marcador no definido.**
1. Correcciones aplicadas a la Fase 1 3
2. Marco inferencial 3
3. Supuesto de independencia de las observaciones 4
   3.1 Dependencia temporal: trimestre de entrevista 5
4. Contrastes de hipótesis 5
   4.1 H1: cobertura de seguro y enfermedad reciente 5
   4.2 H2: edad y enfermedad reciente 7
   4.3 H3: quintil de ingreso y enfermedad reciente 8
   4.4 H4: años de estudio e ingreso per cápita 9
   4.5 H5: área de residencia y enfermedad reciente 10
   4.6 H6: asociación entre seguro y enfermedad controlando otras variables 11
5. Tabla resumen de contrastes 12
6. Conclusión de la Fase 2 13
7. Integridad académica y uso de asistentes de IA 15
Referencias 15

1. Correcciones aplicadas a la Fase 1

No se recibió devolución del docente sobre la Fase 1. Las correcciones siguientes surgen de una revisión propia de la Fase 1 completa, hecha antes de iniciar la inferencia; todas están en el repositorio, y los puntos 1, 2, 3 y 6 se verifican por código al inicio del notebook.

N.º	Qué se encontró	Corrección aplicada
1	En `docs/` había una segunda copia del dataset limpio, generada con una versión anterior de la base (otro factor de expansión). Difería del dataset reproducible en el factor, en 9.497 ingresos y en 4.882 quintiles.	Se eliminó la copia. El único dataset válido es `data/processed/ephc_salud_2024_limpio.csv`, que el notebook de la Fase 1 regenera desde los archivos originales.
2	El diccionario del informe de la Fase 1 tomó dos datos de esa copia obsoleta: factor de expansión "10,26 a 889,47" y quintil 1 con 22,05 % de la muestra.	Valores correctos: factor de expansión entero, de 9 a 894; quintil 1 con 24,05 % de la muestra. Las prevalencias informadas en la Fase 1 (29,30 % y 27,99 %) eran correctas.
3	`README.md`, la bitácora y el diccionario en CSV seguían indicando `tiene_seguro = 1` para los códigos "1 a 6 u 8" de `S01A`. El código 8 no existe.	Se corrigieron los tres archivos: 1 para `S01A` de 1 a 6 y 0 para `S01A = 7`. El código y los resultados no cambian.
4	La hipótesis preliminar 4 (educación e ingreso) incluía a niños y adolescentes, cuyos años de estudio están limitados por la edad.	La hipótesis se evalúa en personas de 25 años o más. El valor con todas las edades se informa como referencia.
5	La Fase 1 trató la edad como una variable de efecto lineal.	Se agrega la variable `grupo_edad` (seis tramos), construida por código, porque la relación entre edad y enfermedad tiene forma de U (sección 4.2).
6	La Fase 1 afirmó que no era posible medir la enfermedad por trimestre, porque los archivos trimestrales no traen `S01A` ni `S03`.	Los cuatro archivos trimestrales contienen las mismas 57.744 personas que la base anual. Al enlazarlos por la clave de persona se recupera el trimestre de entrevista de cada una y, con él, la proporción de enfermedad por trimestre (sección 3.1).
7	Faltaba `statsmodels` en `requirements.txt`.	Se agregó, junto con las instrucciones de reproducción de la Fase 2 en el `README.md`.

2. Marco inferencial

El nivel de significancia, las hipótesis, la regla de decisión y el criterio de corrección se fijaron antes de ejecutar las pruebas. La única decisión tomada a la vista de los datos fue usar la edad en tramos en H6, después de observar en H2 que su relación con la enfermedad no es lineal.

Nivel de significancia. $\alpha = 0{,}05$ para toda la fase. Pruebas bilaterales, salvo H4, cuya dirección ya estaba enunciada en la Fase 1.

Hipótesis. Las cinco hipótesis preliminares de la Fase 1 se contrastan tal como fueron enunciadas. Se agrega H6, derivada de la conclusión de la Fase 1, que pedía evaluar si el patrón principal se mantiene al considerar otras variables. Los seis contrastes cubren cinco familias distintas de pruebas.

	En lenguaje natural	H_0	H_1	Familia de prueba
H1	La proporción de enfermedad reciente difiere entre personas con y sin seguro.	$\pi_{con} = \pi_{sin}$	$\pi_{con} \neq \pi_{sin}$	Comparar dos proporciones
H2	La edad de quienes enfermaron difiere de la de quienes no enfermaron.	$P(X_{enf} > X_{sano}) = 0{,}5$	$P(X_{enf} > X_{sano}) \neq 0{,}5$	Comparar dos grupos independientes
H3	La enfermedad reciente no se distribuye igual entre los quintiles de ingreso.	Enfermedad y quintil son independientes	Existe asociación	Asociación entre dos categóricas
H4	A más años de estudio, mayor ingreso per cápita (25 años o más).	$\rho \leq 0$	$\rho > 0$	Significancia de una correlación

	En lenguaje natural	H_0	H_1	Familia de prueba
H5	La proporción de enfermedad reciente difiere entre el área rural y la urbana.	$\pi_{rural} = \pi_{urbana}$	$\pi_{rural} \neq \pi_{urbana}$	Comparar dos proporciones
H6	El seguro se asocia con la enfermedad al controlar edad, sexo, área y quintil.	$\beta_{seguro} = 0$	$\beta_{seguro} \neq 0$	Efecto de una variable controlando otras

Comparaciones múltiples. Con seis pruebas al 5 %, la probabilidad de al menos un falso positivo sería $1 - 0{,}95^6 = 26{,}5$ % si todas las hipótesis nulas fueran ciertas. La decisión final usa valores p ajustados por Bonferroni sobre los seis contrastes (equivale a exigir $p < 0{,}0083$). Las diez comparaciones post hoc entre quintiles son exploratorias y se ajustan por Benjamini-Hochberg.

Regla de decisión. La sección 3 muestra que las observaciones no son independientes. Por eso la decisión de cada contraste se toma con el **valor p robusto a conglomerados** ajustado por Bonferroni. El valor p clásico, que supone independencia, se informa siempre al lado.

Factor de expansión. Las pruebas se aplican sobre la muestra sin ponderar, porque las pruebas clásicas no admiten pesos muestrales sin un tratamiento de diseño complejo. En H1 se agrega la estimación ponderada como análisis de sensibilidad.

Cantidad de pruebas realizadas. 6 contrastes confirmatorios, 10 comparaciones post hoc y 6 pruebas de supuestos (5 de Shapiro-Wilk y 1 de Levene). Además se informan de forma descriptiva, sin usarlas para decidir sobre ninguna hipótesis, la prueba global del modelo de H6, los intervalos de sus demás coeficientes, los modelos M0 a M4 y la diferencia de H5 controlando el trimestre. No se descartó ningún resultado.

3. Supuesto de independencia de las observaciones

Todas las pruebas clásicas suponen observaciones independientes. La EPHC selecciona unidades primarias de muestreo (UPM), luego viviendas, y entrevista a todos los integrantes de cada hogar, que comparten ingreso, entorno y contagios. El supuesto se verificó con la correlación intraclase (ICC), que mide qué proporción de la variabilidad se debe a pertenecer al mismo conglomerado, y con el efecto de diseño, que indica cuántas veces mayor es la varianza real respecto de la de una muestra aleatoria simple.

Variable	Conglomerado	N.º de conglomerados	Personas por conglomerado	ICC	Efecto de diseño
Enfermedad reciente	Hogar	17.186	3,3	0,306	1,71
Enfermedad reciente	UPM	1.750	32,6	0,055	2,75
Tiene seguro	Hogar	17.186	3,3	0,571	2,33
Tiene seguro	UPM	1.750	32,6	0,181	6,74

El supuesto no se cumple. Dentro del hogar la enfermedad tiene ICC = 0,31: si una persona enfermó, es mucho más probable que otra del mismo hogar también. A nivel de UPM la varianza real de la prevalencia es casi el triple de la que supone una muestra aleatoria simple. En consecuencia, los errores estándar clásicos quedan subestimados y los valores p clásicos son demasiado optimistas.

Decisión. Cada contraste se acompaña de una versión que no supone independencia: errores estándar robustos agrupados por UPM (que contiene a los hogares) o bootstrap por conglomerados, en el que se remuestrean UPM completas en lugar de personas.

3.1 Dependencia temporal: trimestre de entrevista

Las personas entrevistadas en la misma época comparten estación del año y brotes. Con el trimestre recuperado (corrección 6) se describe la proporción de enfermedad a lo largo de 2024. No es un contraste adicional: se muestran las proporciones con su IC 95 % por bootstrap de UPM.

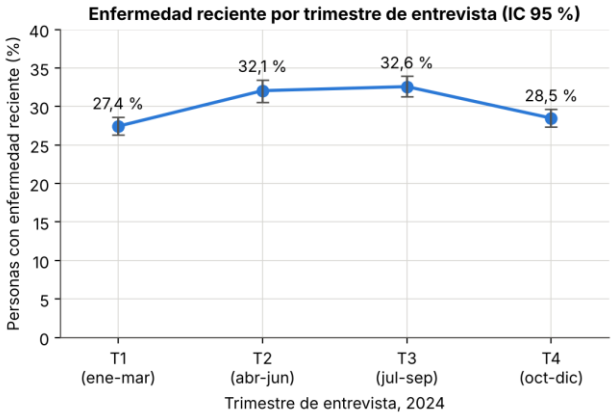


Figura 1. Proporción muestral de enfermedad reciente por trimestre de entrevista, con IC 95 % por bootstrap de UPM.

La proporción es 27,4 % en las entrevistas del primer trimestre y 28,5 % en las del cuarto, frente a 32,1 % y 32,6 % en las del segundo y el tercero. Como la pregunta se refiere a los 90 días anteriores, las entrevistas de mitad de año cubren el otoño y el invierno. Los intervalos de los trimestres centrales no se superponen con los de los extremos: hay un patrón estacional de entre 3,6 y 5,2 puntos porcentuales, mayor que la diferencia entre áreas.

Esto tiene tres consecuencias. Cada UPM se entrevistó en un único trimestre: la dependencia que el trimestre introduce dentro de cada UPM queda cubierta por los errores robustos y el bootstrap por UPM, y la que podría introducir entre UPM del mismo trimestre se comprueba agregando el trimestre como control en H5 y en un modelo de sensibilidad de H6 (M4). El trimestre no confunde la comparación principal, porque la proporción de personas aseguradas es casi la misma en los cuatro trimestres (entre 26,0 % y 26,8 %). Y la base tiene componente temporal, lo que condiciona el diseño de la Fase 3 (sección 6).

4. Contrastes de hipótesis

4.1 H1: cobertura de seguro y enfermedad reciente

Prueba seleccionada. Las dos variables son binarias y los grupos son independientes entre sí, por lo que corresponde la **prueba z de dos proporciones**. Se prefiere al chi-cuadrado 2×2, que es equivalente, porque entrega el intervalo de confianza de la diferencia.

Supuestos. Tamaño suficiente para la aproximación normal: se cumple (el grupo más chico tiene 4.382 éxitos y 10.736 fracasos). Independencia entre observaciones: no se cumple (sección 3), por lo que la prueba se repite con error estándar robusto por UPM.

Resultados. Reportaron enfermedad reciente 4.382 de 15.118 personas con seguro (28,99 %) y 12.780 de 41.991 sin seguro (30,44 %).

Análisis	Diferencia (p.p.)	Error estándar	z	Valor p	IC 95 % (p.p.)
Clásico (supone independencia)	−1,45	0,43	−3,33	0,0009	−2,30 a −0,60
Robusto a conglomerados (UPM)	−1,45	0,57	−2,56	0,010	−2,56 a −0,34

Tamaño del efecto: h de Cohen de −0,03 (trivial; el umbral de un efecto pequeño es 0,2) y riesgo relativo de 0,95.

Intervalo por bootstrap comparado con el clásico. Se estimó el intervalo de la misma diferencia con 2.000 réplicas y el método del percentil, en tres variantes de bootstrap, y se comparó con el intervalo clásico de Wald.

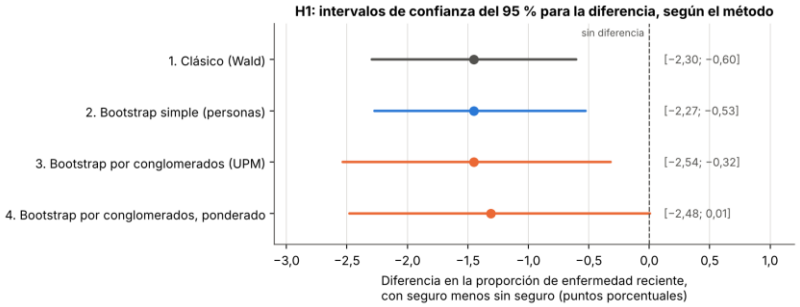


Figura 2. H1: intervalos de confianza del 95 % para la diferencia de proporciones según el método de estimación.

El bootstrap simple, que remuestrea personas, reproduce el intervalo clásico (−2,27 a −0,53 frente a −2,30 a −0,60): cuando se supone lo mismo, la fórmula y el remuestreo coinciden. Al remuestrear UPM completas el intervalo se ensancha alrededor de 30 % (−2,54 a −0,32), porque las personas de un mismo conglomerado aportan menos información independiente de la que su número sugiere. Con el factor de expansión la diferencia estimada es −1,31 p.p. y el intervalo tiene una amplitud similar (−2,48 a 0,01); su extremo superior queda en torno a cero y cambia levemente con la semilla, por lo que no se interpreta si lo incluye o no.

Interpretación. Las personas con seguro reportan enfermedad un punto y medio porcentual menos que las personas sin seguro. Con la prueba clásica la diferencia parece muy significativa (p = 0,0009), pero al reconocer que los integrantes de un hogar tienden a enfermarse juntos el valor p sube a 0,010 y, ajustado por Bonferroni, a 0,063: **no se rechaza H_0** con el criterio declarado. Con criterios menos conservadores sí se rechazaría (Holm: 0,021; Benjamini-Hochberg: 0,013). Una conclusión que cambia según el criterio es evidencia frágil. Aun si la diferencia existiera, sería irrelevante en la práctica: de cada 100 personas enfermaron 29 en un grupo y 30 en el otro.

Posible confusión. Las personas con seguro tienen más edad, más educación y el doble de ingreso mediano (Fase 1), y cualquiera de esas características puede dar cuenta de la diferencia. H6 lo evalúa. Además la enfermedad es autorreportada, y quien tiene seguro podría consultar más y reconocer más episodios; la base no permite comprobarlo.

4.2 H2: edad y enfermedad reciente

Prueba seleccionada. Se compara una variable numérica entre dos grupos independientes. La prueba paramétrica es la t de Student para muestras independientes y su alternativa no paramétrica, la U de Mann-Whitney. La verificación de supuestos decide cuál se usa.

Supuestos.

Supuesto de la t de Student	Verificación	Resultado
Normalidad de la edad en cada grupo	Shapiro-Wilk sobre una submuestra aleatoria de 5.000 casos por grupo: W = 0,948 (enfermos) y 0,961 (sanos); p < 0,001 en ambos. Gráficos Q-Q con desvíos en las dos colas	No se cumple
Homogeneidad de varianzas	Levene centrado en la mediana: W = 1.356; gl = (1; 57.107); p < 0,001. Razón de varianzas = 1,41	No se cumple
Independencia	ICC por hogar = 0,31	No se cumple

Shapiro-Wilk se aplica sobre una submuestra porque su valor p no es exacto con más de 5.000 observaciones.

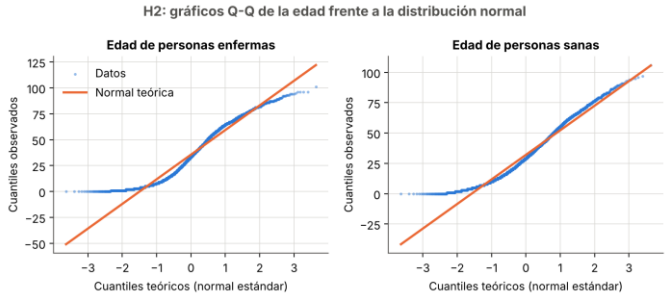


Figura 3. H2: gráficos Q-Q de la edad. Los puntos se apartan de la recta en ambas colas: la edad no puede ser negativa y su cola derecha es más corta que la de una normal.

Decisión. Se descarta la t de Student y se aplica la **U de Mann-Whitney**, que no requiere normalidad. Su valor p clásico supone distribuciones de igual forma bajo H_0 e independencia, y ninguna de las dos condiciones se cumple del todo; por eso la decisión se apoya en la versión robusta, con el error estándar de la probabilidad de superioridad estimado por bootstrap de UPM.

Resultados. La mediana de edad es 33 años entre las 17.162 personas enfermas y 29 entre las 39.947 sanas (diferencia de 4 años; IC 95 % por bootstrap: 3 a 5).

- Clásico: U = 364.551.071; z = 12,05; p < 0,001.
- Robusto: z = 9,70; p < 0,001. La probabilidad de que una persona enferma tomada al azar tenga más edad que una sana es 0,532, contando los empates como medio (IC 95 %: 0,526 a 0,538).
- Tamaño del efecto: correlación biserial por rangos = 0,06 (trivial). Como referencia, d de Cohen = 0,16.

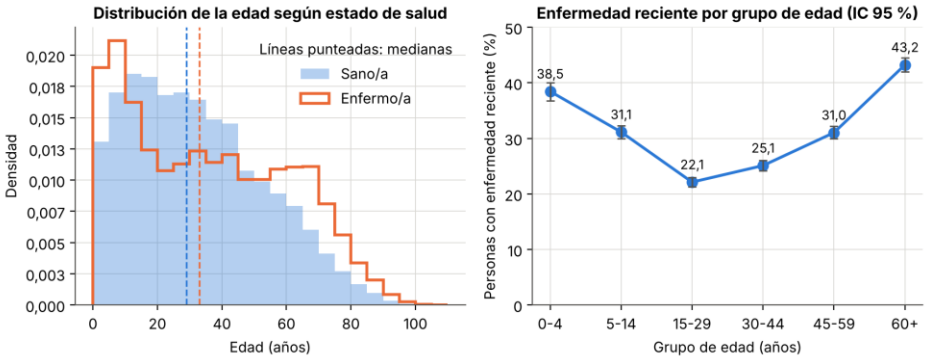


Figura 4. H2: distribución de la edad según estado de salud (izquierda) y proporción de enfermedad reciente por grupo de edad con IC 95 % por bootstrap de UPM (derecha).

Interpretación. Se rechaza H_0: las personas que enfermaron tienden a ser algo mayores. Pero la superposición es casi total: la enferma es la mayor en alrededor del 53 % de los pares, apenas por encima del 50 % que daría el azar. La figura explica por qué un efecto tan chico convive con una relación fuerte: la proporción de enfermedad tiene **forma de U**. Es alta en menores de 5 años (38,5 %), mínima entre los 15 y 29 (22,1 %) y máxima desde los 60 (43,2 %). Una prueba de dos grupos solo detecta desplazamientos en un sentido, y aquí niños y adultos mayores se compensan. La edad importa, pero no de forma lineal; por eso en H6 se usa en tramos.

Posible confusión. El sexo: en la muestra las mujeres tienen algo más de edad en promedio (33,4 frente a 32,5 años) y reportan más enfermedad. Además, la información de los niños pequeños la reporta un adulto del hogar.

4.3 H3: quintil de ingreso y enfermedad reciente

Prueba seleccionada. Dos variables categóricas (cinco quintiles por dos estados de salud): **chi-cuadrado de independencia**, con V de Cramér como tamaño del efecto. Se excluyen 130 personas sin ingreso informado (0,23 %); n = 56.979.

Supuestos. Frecuencias esperadas de al menos 5: se cumple (mínima esperada 3.059), por lo que no hace falta la prueba exacta de Fisher. Independencia: no se cumple, porque el quintil es del hogar y todos sus integrantes comparten la misma fila de la tabla. Se agrega una prueba de Wald robusta: modelo logístico de enfermedad sobre el quintil con covarianzas agrupadas por UPM, donde se contrasta que los cuatro coeficientes sean cero a la vez.

Resultados.

- Clásico: $\chi^2 = 211{,}9$; gl = 4; $p < 0{,}001$.
- Robusto: χ^2 de Wald = 110,9; gl = 4; $p < 0{,}001$. El estadístico se reduce casi a la mitad, pero la conclusión se mantiene con holgura.
- Tamaño del efecto: V de Cramér = 0,061 (IC 95 % por bootstrap de UPM: 0,051 a 0,073), trivial según la convención.

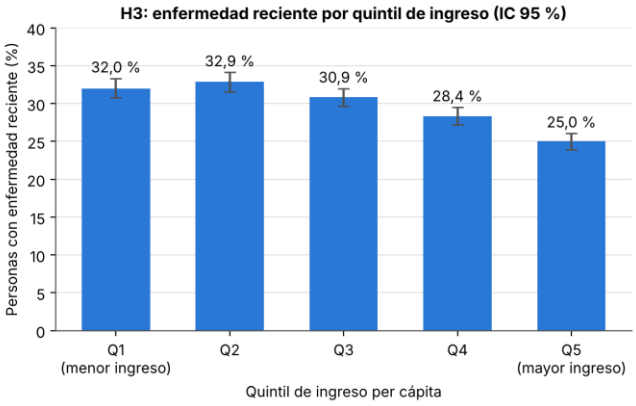


Figura 5. H3: proporción muestral de enfermedad reciente por quintil de ingreso, con IC 95 % por bootstrap de UPM.

Post hoc. Se compararon los diez pares de quintiles con la prueba z robusta, ajustando por Benjamini-Hochberg (con diez pruebas al 5 %, la probabilidad de al menos un falso positivo sería de 40 %). Ocho comparaciones resultan significativas: todas las que involucran a los quintiles 4 o 5 y la del quintil 2 frente al 3. El quintil 1 no difiere del 2 ni del 3. Los residuos estandarizados ajustados coinciden: el quintil 5 tiene muchos menos enfermos que los esperados (−12,3) y los quintiles 1 y 2 tienen más (5,7 y 7,6).

Interpretación. Se rechaza H_0. Las personas de hogares con mayores ingresos reportan menos enfermedad: en el quintil más alto enfermó 1 de cada 4 personas; en los tres más bajos, casi 1 de cada 3. No es un descenso parejo: las diferencias son chicas en los ingresos bajos y medios y grandes en los altos. La V es baja porque resume toda la tabla, incluidos tres quintiles con proporciones cercanas; la diferencia entre el quintil 2 y el 5 es de 7,9 p.p. (IC 95 %: 6,3 a 9,6), la mayor encontrada entre grupos socioeconómicos, y sí tiene relevancia práctica.

Posible confusión. El ingreso se relaciona con el área, con la edad de los integrantes del hogar y con el seguro. También podría haber causalidad inversa: una persona enferma puede trabajar menos y reducir el ingreso del hogar.

4.4 H4: años de estudio e ingreso per cápita

Población y prueba. Personas de 25 años o más con ambos datos (n = 33.487). Se evalúa la significancia de una correlación: la prueba paramétrica es la de r de Pearson y la alternativa, la de ρ de Spearman.

Supuestos.

Supuesto de la prueba de Pearson	**Verificación**	**Resultado**
Normalidad de ambas variables	Shapiro-Wilk: $p < 0{,}001$ en las dos. Asimetría del ingreso = 10,9; curtosis = 259. Tampoco se logra con logaritmo	No se cumple
Relación lineal	La mediana del ingreso crece de forma convexa con los años de estudio (figura 6)	No se cumple
Sin valores extremos influyentes	El ingreso máximo es 96 veces la mediana	No se cumple
Relación monótona (Spearman)	La mediana crece con los años de estudio; las bajas son menores a 1 % salvo entre 9 y 10 años (8 %)	Se cumple de forma aproximada
Independencia	El ingreso per cápita es el mismo para todo el hogar	No se cumple

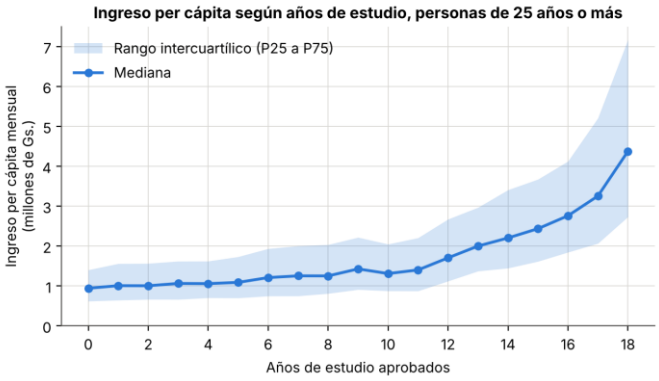


Figura 6. H4: mediana y rango intercuartílico del ingreso per cápita según años de estudio. La relación es creciente pero no lineal, y la dispersión aumenta con la educación.

Decisión. Se descarta Pearson y se aplica la prueba unilateral sobre **ρ de Spearman**, con intervalo de confianza y valor p robusto por bootstrap de UPM.

Resultados. ρ = 0,470.

- Clásico: t = 97,5; gl = 33.485; p < 0,001. IC 95 % por transformación de Fisher: 0,461 a 0,479.
- Robusto: IC 95 % por bootstrap de UPM: 0,457 a 0,483; z = 68; p < 0,001. El intervalo es cerca de 50 % más ancho que el clásico, pero queda muy lejos de cero.
- Tamaño del efecto: mediano, cercano al umbral de efecto grande (0,5).
- Referencias: r de Pearson = 0,281, menor que ρ porque los ingresos extremos y la curvatura atenúan la correlación lineal. Con todas las edades, ρ = 0,393 (el valor de la Fase 1).

Interpretación. Se rechaza H_0. Entre los adultos, quienes estudiaron más años viven en hogares con mayor ingreso por persona: la mediana con 16 años de estudio (2,76 millones de Gs.) es más del doble de la mediana con 6 años (1,21 millones). Es el contraste con el mayor efecto estandarizado de la fase.

Posible confusión. La edad y la generación pueden relacionarse con ambas variables, igual que el área de residencia. Además el ingreso es del hogar y per cápita: depende de cuántas personas viven en él y de lo que ganan los demás, no solo de la educación de la persona. No se afirma que estudiar más cause mayor ingreso.

4.5 H5: área de residencia y enfermedad reciente

Prueba seleccionada. Igual que en H1: **prueba z de dos proporciones**.

Supuestos. Tamaño: se cumple (mínimo 7.700 éxitos). Independencia: no se cumple, y aquí pesa más que en H1, porque el área es una característica de la UPM entera (ninguna de las 1.750 UPM mezcla áreas).

Resultados. Reportaron enfermedad 7.700 de 24.181 personas del área rural (31,84 %) y 9.462 de 32.928 del área urbana (28,74 %).

Análisis	Diferencia (p.p.)	z	Valor p	IC 95 % (p.p.)

Análisis	Diferencia (p.p.)	z	Valor p	IC 95 % (p.p.)
Clásico (supone independencia)	3,11	8,00	< 0,001	2,34 a 3,87
Robusto a conglomerados (UPM)	3,11	4,69	< 0,001	1,81 a 4,41

IC 95 % por bootstrap de UPM: 1,84 a 4,42 p.p. Tamaño del efecto: h de Cohen de 0,07 (trivial) y riesgo relativo de 1,11. El efecto de diseño de esta diferencia es 2,9: la muestra informa como si fueran unas 19.700 personas independientes y no 57.109. Entre personas entrevistadas en el mismo trimestre la diferencia es de 3,20 p.p. (IC 95 % robusto: 1,92 a 4,47).

Interpretación. Se rechaza H_0. En el área rural enfermaron unas 32 de cada 100 personas y en la urbana, unas 29. El estadístico baja de 8,00 a 4,69 con el análisis robusto, pero la conclusión no cambia. El efecto estandarizado es chico; aun así, una diferencia de 3 puntos en una proporción que ronda el 30 % puede importar para planificar servicios de salud, aunque no sirva para predecir casos individuales.

Posible confusión. El área rural concentra hogares de menores ingresos, y el ingreso también se asocia con la enfermedad (H3). El modelo de H6 incluye área y quintil a la vez.

4.6 H6: asociación entre seguro y enfermedad controlando otras variables

Prueba seleccionada. Evaluar la asociación de una variable con la respuesta controlando otras corresponde a una regresión múltiple con prueba sobre el coeficiente. Como la respuesta es binaria, una regresión lineal incumpliría por construcción la normalidad y la homogeneidad de los residuos; se usa su equivalente para respuestas binarias, la **regresión logística**, con prueba de Wald sobre el coeficiente del seguro y errores estándar robustos por UPM.

Controles. Edad en seis tramos (por su relación en U), sexo, área y quintil de ingreso. Los años de estudio no se incluyen: faltan en el 83 % de los menores de 5 años, el grupo con más enfermedad. n = 56.979.

Supuestos. Multicolinealidad: VIF máximo = 1,80 y VIF del seguro = 1,25, por debajo de 5 (se cumple). Linealidad del logit: no aplica, porque todos los predictores son categóricos. Tamaño: 1.428 eventos por parámetro, el ajuste converge y no hay celdas vacías (se cumple). Independencia: no se cumple; se usan errores robustos por UPM.

Resultados.

- Coeficiente del seguro: razón de odds (OR) ajustada = 1,007; IC 95 % robusto: 0,951 a 1,065; z robusto = 0,22; p = 0,82. Clásico: z = 0,27; p = 0,78.
- Efecto marginal promedio: +0,13 p.p. (IC 95 %: −1,03 a 1,29).
- Prueba global del modelo: Wald robusto χ^2 = 1.489; gl = 12; p < 0,001. Pseudo R^2 de McFadden = 0,025.

Análisis de confusión. Para ver con qué variable cambia la diferencia bruta se agregaron los controles de a uno. Estos modelos intermedios son descriptivos y no se usan para decisiones adicionales.

Modelo	OR del seguro	IC 95 % robusto
M0. Solo seguro (bruto)	0,932	0,883 a 0,983
M1. + edad	0,886	0,839 a 0,936
M2. + edad, sexo y área	0,910	0,861 a 0,962

Modelo	OR del seguro	IC 95 % robusto
M3. + edad, sexo, área y quintil	1,007	0,951 a 1,065
M4. M3 + trimestre (sensibilidad)	1,005	0,949 a 1,063

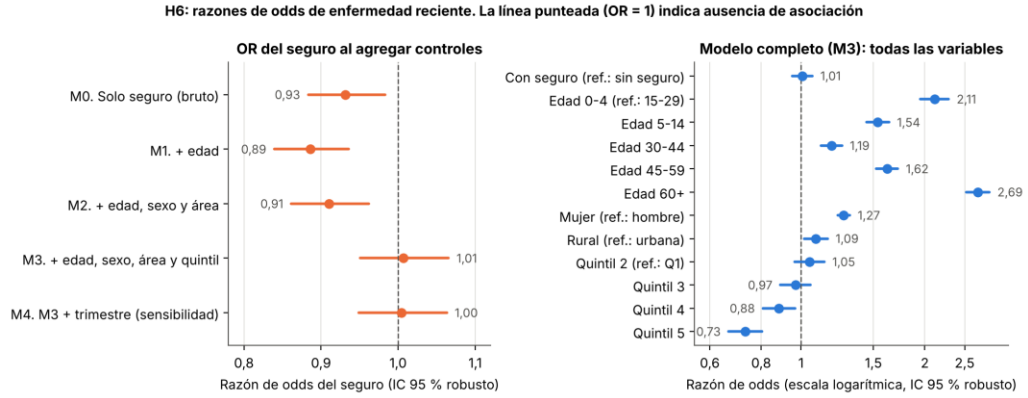


Figura 7. H6: razón de odds del seguro al agregar controles (izquierda) y razones de odds de todas las variables del modelo completo (derecha), con IC 95 % robustos.

Interpretación. No se rechaza H_0. Al comparar personas de la misma edad, sexo, área y nivel de ingreso, quienes tienen seguro y quienes no lo tienen reportan enfermedad prácticamente en la misma proporción. El recorrido del OR muestra dos variables que lo mueven en sentidos opuestos. Los asegurados son mayores y los mayores enferman más, de modo que a igual edad la diferencia es algo más marcada: el OR baja de 0,93 a 0,89. Al agregar el quintil de ingreso el OR sube a 1,01: los asegurados pertenecen a hogares de mayores ingresos, y esos hogares reportan menos enfermedad, tengan o no seguro. Agregar el trimestre de entrevista no lo modifica (1,005).

No rechazar H_0 no demuestra que no exista asociación. Lo que muestran los datos es que el intervalo es estrecho: es compatible, como mucho, con una diferencia de alrededor de 1 punto porcentual en cualquier sentido. Tampoco es un efecto causal: es una comparación ajustada en datos observacionales.

El modelo completo muestra además qué variables sí se asocian con la enfermedad: la edad (menores de 5 años, OR = 2,11; 60 años o más, OR = 2,69, ambos respecto del grupo de 15 a 29), el sexo (mujeres, OR = 1,27), el quintil 5 (OR = 0,73) y, en menor medida, el área rural (OR = 1,09).

Confusión no controlada. Quedan fuera variables no medidas en la base: enfermedades crónicas previas, tipo de empleo y la forma en que cada persona percibe o recuerda sus episodios de enfermedad.

5. Tabla resumen de contrastes

La tabla se genera por código en la Parte 3 del notebook a partir de los resultados que registra cada parte (`output/fase2/tabla_resumen_contrastes.csv`). Se presenta en dos bloques por razones de espacio.

	Hipótesis	Prueba aplicada	Supuestos verificados	Decisión
H1	Enfermedad difiere según seguro	z de dos proporciones	Tamaño: cumple. Independencia: no cumple, EE robusto por UPM	No se rechaza H_0

	Hipótesis	Prueba aplicada	Supuestos verificados	Decisión
H2	Edad difiere según enfermedad	U de Mann-Whitney	Normalidad (Shapiro-Wilk, Q-Q) y varianzas (Levene): no cumplen; se descarta t de Student	Se rechaza H_0
H3	Enfermedad difiere según quintil	Chi-cuadrado de independencia	Esperadas de al menos 5: cumple. Independencia: no cumple, Wald robusto por UPM	Se rechaza H_0
H4	Asociación positiva educación e ingreso	ρ de Spearman, unilateral	Normalidad, linealidad y extremos: no cumplen; se descarta Pearson. Monotonía: cumple de forma aproximada	Se rechaza H_0
H5	Enfermedad difiere según área	z de dos proporciones	Tamaño: cumple. Independencia: no cumple, EE robusto por UPM	Se rechaza H_0
H6	Seguro asociado al controlar otras variables	Regresión logística, Wald	VIF menor a 2, tamaño y convergencia: cumplen. Independencia: no cumple, EE robustos por UPM	No se rechaza H_0

	n	Estadístico (gl)	p clásico	p robusto	p robusto, Bonferroni	IC 95 %	Tamaño del efecto
H1	57.109	z = −3,33	< 0,001	0,010	0,063	Diferencia: −2,54 a −0,32 p.p.	h = −0,032 (trivial)
H2	57.109	z = 12,05	< 0,001	< 0,001	< 0,001	P(enf > sano): 0,526 a 0,538	r biserial = 0,063 (trivial)
H3	56.979	χ^2 = 211,91 (4)	< 0,001	< 0,001	< 0,001	V: 0,051 a 0,073	V = 0,061 (trivial)
H4	33.487	t = 97,51 (33.485)	< 0,001	< 0,001	< 0,001	ρ: 0,457 a 0,483	ρ = 0,470 (mediano)
H5	57.109	z = 8,00	< 0,001	< 0,001	< 0,001	Diferencia: 1,84 a 4,42 p.p.	h = 0,068 (trivial)
H6	56.979	z = 0,27	0,784	0,823	1,000	OR: 0,951 a 1,065	OR = 1,007 (trivial)

Los intervalos de H1 a H5 son por bootstrap de UPM y el de H6 es de Wald robusto. H1 es el único contraste cuya decisión depende del método: con el análisis clásico y Bonferroni se rechazaría (p ajustado = 0,005), y también con el valor p robusto ajustado por Holm (0,021) o por Benjamini-Hochberg (0,013).

6. Conclusión de la Fase 2

Hipótesis que se sostuvieron. H2 (edad), H3 (quintil de ingreso), H4 (educación e ingreso) y H5 (área) se sostienen con cualquier criterio: clásico o robusto, con Bonferroni, Holm o Benjamini-Hochberg. H1 (seguro, en bruto) no se sostiene con el criterio declarado de antemano y su evidencia es frágil. H6 (seguro, controlando otras variables) no se sostiene con ningún criterio.

Implicancias para la pregunta de investigación. La pregunta era si la proporción de personas que reportaron enfermedad en los últimos 90 días difiere entre quienes tienen y quienes no tienen seguro médico.

1. En bruto, la diferencia es de 1,45 puntos porcentuales (28,99 % con seguro y 30,44 % sin seguro). Es demasiado pequeña para tener relevancia práctica y, considerada la dependencia entre integrantes de un mismo hogar, no alcanza significancia con el criterio de corrección declarado (Bonferroni), aunque sí con criterios menos conservadores.

2. Al comparar personas de igual edad, sexo, área e ingreso, la diferencia deja de observarse (OR = 1,01; IC 95 %: 0,95 a 1,07). La diferencia bruta coincide con la distinta composición por ingreso de los hogares asegurados.
3. Lo que sí se asocia con la enfermedad reciente es la edad (en forma de U), el sexo, el quintil de ingreso y, en menor medida, el área. De forma descriptiva se observa además un patrón por trimestre de entrevista (sección 3.1).

Ninguna de estas asociaciones puede leerse como causal: la EPHC es una encuesta transversal y observacional.

Limitaciones de la inferencia.

- *Dependencia entre observaciones.* Es la limitación principal. Se abordó con errores robustos y bootstrap por UPM, pero no se dispone de los estratos del diseño muestral, por lo que los errores estándar siguen siendo aproximados.
- *Representatividad.* Las pruebas se hicieron sobre la muestra sin ponderar, que sobrerrepresenta áreas rurales y departamentos chicos. En H1 la estimación ponderada (−1,31 p.p.) lleva a la misma conclusión.
- *Tamaño muestral.* Con 57.109 personas, diferencias mínimas resultan significativas en las pruebas clásicas. Por eso las conclusiones se apoyan en el tamaño del efecto y no solo en el valor p.
- *Dependencia temporal.* Hay un patrón estacional (sección 3.1). La dependencia que introduce dentro de cada UPM queda cubierta por los errores por UPM, y agregar el trimestre como control en H5 y en H6 no cambia los resultados. Quedan dos límites: solo se dispone del trimestre, no de la fecha exacta, y con un único año no puede separarse la estación de otros hechos ocurridos en 2024.
- *Medición.* La enfermedad es autorreportada con un recuerdo de 90 días, y en niños la reporta un adulto.
- *Datos faltantes.* Se excluyeron 130 personas sin ingreso (0,23 %) en H3 y H6; el impacto esperado es mínimo.

Variables que se llevan al modelo predictivo de la Fase 3.

Variable	Decisión	Evidencia de esta fase
Edad	Se incluye, en tramos o con un modelo que capte relaciones no lineales	Relación en U; es el predictor más fuerte en H6
Sexo	Se incluye	OR = 1,27 en el modelo de H6
Quintil o ingreso per cápita	Se incluye	H3; es la variable que más modifica la asociación del seguro en H6
Área	Se incluye	H5; conserva asociación propia en H6 (OR = 1,09)
Trimestre de entrevista	Depende de la partición (ver abajo)	Patrón estacional de 3,6 a 5,2 p.p. (sección 3.1)
Tiene seguro	Se incluye, por ser la variable de la pregunta de investigación	Sin asociación propia en H6: se espera una importancia baja, que la Fase 3 debe confirmar
Años de estudio	Se evalúa con cuidado	Correlacionado con el ingreso (H4) y sin dato en menores de 5 años
Departamento y estado civil	Se evalúan en la Fase 3	No fueron contrastados en esta fase

De esta evidencia surgen tres advertencias para el diseño de la Fase 3. Primero, **la partición no debe separar personas del mismo hogar ni de la misma UPM**: como los integrantes de un

hogar tienden a enfermarse juntos, repartirlos al azar entre entrenamiento y prueba filtraría información y haría parecer al modelo mejor de lo que es. Segundo, **la base tiene componente temporal y hay dos diseños de partición válidos**. El cronológico (entrenar con los tres primeros trimestres y probar con el cuarto) cumple con el punto anterior, porque cada UPM pertenece a un solo trimestre, pero impide usar el trimestre como predictor y deja un conjunto de prueba de otra composición: 28,5 % de enfermedad frente a 30,7 % en el entrenamiento, y 46,1 % de área rural frente a 40,9 %. El agrupado por UPM, sin orden temporal, permite usar el trimestre como predictor. La consigna pide partición cronológica cuando hay componente temporal, por lo que se propone el primero como diseño principal y el segundo como comprobación; la decisión se toma y se justifica en la Fase 3. Tercero, cabe esperar un desempeño predictivo modesto, porque el modelo de H6 tiene un pseudo R^2 de 0,025.

7. Integridad académica y uso de asistentes de IA

En esta fase se utilizó un asistente de inteligencia artificial (Claude, de Anthropic) con un alcance mayor que en la Fase 1. Se declara en detalle para qué se empleó:

- **Código.** El asistente generó los módulos de `src/fase2/` y los tres notebooks de la fase.
- **Diseño del análisis.** El asistente propuso la prueba para cada hipótesis, las verificaciones de supuestos, el tratamiento de la dependencia por conglomerados, el criterio de corrección por comparaciones múltiples y la incorporación de H6.
- **Redacción.** El asistente elaboró el borrador de este informe y de las celdas de texto de los notebooks, incluidas las interpretaciones.
- **Revisión de la Fase 1.** El asistente detectó las inconsistencias listadas en la sección 1.
- **Verificación.** Una segunda instancia del asistente recalculó de forma independiente las cifras del informe y señaló correcciones de redacción, que se aplicaron.

Cada integrante tiene a su cargo la parte indicada en el `README.md` del repositorio (código, ejecución y explicación) y responde por ella, y por el resto del trabajo, en la presentación final.

Referencias

Instituto Nacional de Estadística (INE Paraguay). *Encuesta Permanente de Hogares Continua (EPHC) 2024*, base anual REG02 con Factor Revisión 2025. https://www.ine.gov.py/microdato/

Documentación oficial de pandas, scipy.stats y statsmodels.