Informe Fase 3 Grupo 4: cobertura de seguro médico (EPHC 2024)

Carrera: Ingeniería Informática · **Materia:** Data Science · **Proyecto Integrador de Ciencia de Datos**

Fase 3: Análisis predictivo

Título: Perfiles socioeconómicos y clasificación de la falta de seguro médico en adultos de Paraguay (EPHC 2024)

Grupo 4

Integrante	C.I.
Kyara Ivanna Popov Araujo	5403389
Zinri Alice Bobadilla Peralta	5306066
Alejandro Sanabria Penayo	5689736

Asunción, 10 de noviembre de 2026

Índice

1. Correcciones aplicadas a la Fase 2
2. Reformulación de la pregunta y tarea predictiva
3. Datos y preparación para el modelado
4. Partición, validación y línea base
5. Perfiles por clustering
6. Modelos e hiperparámetros
7. Resultados y sobreajuste
8. Análisis de errores
9. Interpretación del modelo y NBI territorial
10. Conclusión de la Fase 3
11. Reproducción, uso de asistentes de IA y referencias

1. Correcciones aplicadas a la Fase 2

La devolución de la Fase 2 pidió explicar mejor los resultados y, finalmente, reorientar el proyecto, porque la asociación buscada no era lo bastante fuerte. Se aplicaron estas correcciones:

1. Explicar qué es el OR y por qué vale 1,007. Se explicó con los conteos: las odds de enfermar con seguro son 4.382 ÷ 10.736 = 0,41 y sin seguro 12.780 ÷ 29.211 = 0,44, lo que da un OR bruto de 0,93. El 1,007 es e elevado al peso del seguro (0,0065) en la regresión logística que compara personas de igual edad, sexo, área e ingreso. La diferencia bruta se explica por el mayor ingreso de los asegurados.

2. Explicar la regresión logística y sus cálculos. Se documentó el modelo M3 con todos sus pesos y con ejemplos de cálculo de probabilidad. A igual perfil, el seguro cambia el riesgo de enfermar en 0,2 puntos.

3. Concluir hipótesis por hipótesis. Se redactó el estado de H1 a H6 en lenguaje simple: H2 a H5 se sostienen, H1 es frágil y H6 no se sostiene.

4. Estimación base con dos algoritmos. Se entrenaron una línea base, una regresión logística y un Random Forest para predecir la enfermedad reciente. Obtuvieron un AUC de 0,62 a 0,63, apenas por encima de una regla que usa solo la edad (0,605), y el seguro no aportó a la predicción.

5. Buscar una asociación más fuerte con clustering, zonas y NBI. Se agrupó a la población en seis perfiles, se clasificó la enfermedad reciente y se cruzó con el NBI departamental. Los perfiles reportaban enfermedad entre el 19,7 % y el 40,4 %, pero estaban poco separados (silhouette 0,199) y sus diferencias se explicaban sobre todo por la edad. El Random Forest logró un AUC de 0,624 y una exactitud de 72,61 %, casi igual a la de la línea base (72,47 %), y detectó solo al 3,06 % de los enfermos. La correlación entre el NBI y la enfermedad fue negativa y no significativa ($\rho = -0{,}243$; $p = 0{,}365$).

6. Reestructurar el enfoque. Se cambió la variable objetivo a la **ausencia de seguro médico** (ver sección 2), un problema con señal clara: el modelo final alcanza un AUC de 0,793.

Las Fases 1 y 2 **no se reescriben**: se conservan como el diagnóstico que justificó el cambio. El intento de clustering sobre enfermedad se conserva en la rama `fase3-perfiles-nbi-modelos` del repositorio.

2. Reformulación de la pregunta y tarea predictiva

Por qué cambiar. Las Fases 1 y 2 mostraron que el seguro no se asocia con enfermarse cuando se compara a personas parecidas (OR ajustado 1,007), y que la enfermedad reciente es difícil de predecir con las variables de la encuesta. En cambio, la Fase 2 mostró

una relación muy fuerte entre el seguro y el nivel socioeconómico: tiene seguro el 4,8 % del quintil más pobre y el 57,3 % del más rico en la muestra (entre adultos y con ponderación, 6,2 % y 57,7 %). La falta de cobertura es, además, un problema de acceso a la salud relevante por sí mismo.

Pregunta de la Fase 3: ¿Qué perfiles sociodemográficos y socioeconómicos se asocian con la falta de seguro médico entre adultos de Paraguay en 2024, y en qué medida esas características permiten clasificar esa condición?

Tarea predictiva. Clasificación binaria. Variable objetivo: `sin_seguro` (1 si S01A = 7, "no tiene seguro"; 0 si S01A está entre 1 y 6). Se vincula con el objetivo específico de construir y evaluar un modelo predictivo, ahora aplicado a la cobertura.

Para qué serviría. Para orientar campañas de afiliación o de información sobre cobertura hacia los perfiles y territorios con más probabilidad de no tener seguro. **No** sirve para diagnosticar ni para predecir enfermedad.

3. Datos y preparación para el modelado

Población. Se parte de la base original REG02 EPHC Anual 2024 (57.744 personas) y se conservan los adultos de 18 años o más con respuesta válida sobre seguro (S01A entre 1 y 7) y factor de expansión positivo: **40.266 adultos**. A diferencia de las Fases 1 y 2, los accidentados vuelven a entrar, porque la exclusión tenía sentido solo para estudiar enfermedad. Se trabaja con adultos para que la dependencia de los niños respecto de la cobertura de sus padres no domine los perfiles.

Prevalencia. El 72,1 % de la muestra (29.044 adultos) no tiene seguro; con el factor de expansión, el **68,4 %** de la población adulta. La prevalencia es estable entre trimestres (de 67,9 % a 69,0 %).

Cobertura por quintil de ingreso (adultos, ponderada).

Quintil	1	2	3	4	5
Con seguro, quintiles oficiales del INE	6,2 %	15,0 %	28,0 %	38,4 %	57,7 %
Con seguro, quintiles de la muestra de adultos	5,9 %	14,7 %	27,6 %	39,7 %	58,3 %

La primera fila usa la variable de quintil de la encuesta, que el INE calcula sobre toda la población; es la que se cita en este informe. La segunda divide a los adultos de la muestra en cinco grupos de igual tamaño; es la que se usó en el piloto y en la presentación. Las dos muestran el mismo gradiente. Fuente: `output/fase3/complementos/cobertura_por_quintil.csv`.

Variable	Origen	Preparación	Por qué se incluye
edad	P02	Numérica, estandarizada	La cobertura cambia con la etapa de vida y el empleo
anios_estudio	añoest (99 = faltante)	Numérica, mediana para 15 faltantes, estandarizada	H4 mostró su relación con el ingreso (ρ = 0,47)
log_ingreso	ipcm	ln(1 + ingreso), mediana para 117 faltantes, estandarizada	En la Fase 2 el seguro pasó de 4,8 % a 57,3 % entre quintiles
sexo	P06	One-hot	Control demográfico
area	AREA	One-hot	H5 mostró diferencias urbano y rural; cobertura 36,9 % urbana y 17,4 % rural
departamento	DPTO	One-hot (16 categorías)	Captura diferencias territoriales

Decisiones de preparación.

- Toda la imputación, el escalado y la codificación se hacen dentro de un `Pipeline` de scikit-learn, que se ajusta **solo con los datos de entrenamiento** de cada partición. Así la prueba no filtra información al preprocesamiento. Se agrega un indicador de faltante para las numéricas.
- **No se usan** el quintil y el ingreso a la vez (miden lo mismo), ni la enfermedad, el tipo de seguro, la UPM o los identificadores, para evitar fuga de información.
- **Desbalance:** la clase "sin seguro" es la mayoritaria (68 %). No se remuestrea; en cambio, se reportan métricas que no dependen del balance (AUC, exactitud balanceada, F1 y precisión y exhaustividad por clase).
- **Ponderación:** los modelos se entrenan con el factor de expansión como peso de cada persona, y las métricas también se calculan ponderadas, para que representen a la población y no solo a la muestra.

4. Partición, validación y línea base

Partición cronológica. La EPHC tiene componente temporal (trimestre de entrevista), así que no se usa una partición aleatoria. El trimestre se recupera enlazando cada persona con los cuatro archivos REG02 trimestrales por UPM, vivienda, hogar y línea.

Conjunto	Trimestres	Adultos	Uso
Desarrollo	1 a 3	28.816	Entrenar y validar
Prueba	4	11.450	Evaluación final, una sola vez

Cada una de las 1.750 UPM fue entrevistada en un único trimestre; el código verifica que ninguna UPM aparezca en desarrollo y prueba a la vez. Así, ningún hogar queda repartido entre ambos conjuntos.

Validación cruzada temporal (origen expansivo). Dentro del desarrollo se valida dos veces, siempre entrenando con el pasado y validando con el trimestre siguiente: entrenar con T1 y validar con T2; entrenar con T1 y T2 y validar con T3. La configuración ganadora se elige por el AUC promedio de esas dos validaciones, sin mirar T4.

Línea base. Un clasificador que predice siempre la clase mayoritaria ("sin seguro"). Acierta en el 67,9 % de los adultos de T4, pero no distingue a nadie: su AUC es 0,5 y su exactitud balanceada 0,5. Todo modelo debe superarla.

5. Perfiles por clustering

Método. MiniBatchKMeans sobre edad, años de estudio, ingreso (log), sexo y área, preparados con el mismo pipeline. **El seguro no entra en el clustering:** la cobertura de cada perfil se calcula después, para no fabricar grupos a partir de la respuesta. El modelo se ajusta con los trimestres 1 a 3 y los adultos de T4 se asignan al perfil más cercano.

Elección de k. Se probaron k = 3 a 6 y se eligió el de mayor coeficiente silhouette (de −1 a 1; cuanto más alto, mejor separados los grupos):

k	3	4	5	6
Silhouette	**0,224**	0,184	0,186	0,192

Perfiles en el conjunto de prueba (T4). Porcentajes y promedios ponderados con el factor de expansión; el ingreso es la mediana de la muestra.

Perfil	Adultos	Sin seguro	Edad media	Años de estudio	Ingreso mediano (Gs./mes)	Rural
A. Adultos con más educación e ingreso	4.089	**49,2 %**	38,9	13,8	2.967.491	12,8 %
B. Mayores con poca educación	4.274	**79,2 %**	58,4	5,0	1.149.139	44,1 %

Perfil	Adultos	Sin seguro	Edad media	Años de estudio	Ingreso mediano (Gs./mes)	Rural
C. Jóvenes de bajo ingreso	3.087	**85,0 %**	28,1	10,4	1.023.361	40,6 %

Lectura. Los perfiles muestran desigualdades grandes: en el perfil A la mitad no tiene seguro; en los perfiles B y C, ocho de cada diez. Los resultados de T4 replican los del desarrollo (48,0 %, 80,1 % y 86,5 %).

Limitaciones del clustering.

- **Separación modesta:** una silhouette de 0,224 indica grupos que se superponen bastante; son una forma útil de resumir, no categorías naturales.
- **Estabilidad irregular:** al repetir el algoritmo con otras semillas, la coincidencia con los perfiles originales (índice de Rand ajustado, ARI) fue 0,40, 0,36 y 0,76, con promedio 0,51.
- **No mejoran la predicción:** el mejor modelo con el perfil como variable logró un AUC de validación de 0,8005, frente a 0,8007 sin él. Por eso el clustering se usa para **describir**, y el modelo final no lo incluye.

6. Modelos e hiperparámetros

Se entrenaron tres familias distintas, todas con el mismo preprocesamiento y con el factor de expansión como peso:

Familia	Modelo	Hiperparámetros oficiales	Idea
Lineal	Regresión logística	C = 1 (regularización), máx. 700 iteraciones	Suma pesos y los convierte en probabilidad; interpretable como OR
Árboles	Random Forest	120 árboles, profundidad máx. 13, mín. 35 personas por hoja	Muchos árboles que votan; capta relaciones no lineales
Boosting	HistGradientBoosting	Tasa de aprendizaje 0,06, 150 iteraciones, máx. 15 hojas, regularización L2 = 4	Árboles secuenciales que corrigen los errores del anterior

Búsqueda en grilla. Para verificar que esos valores fueran adecuados se probaron **22 configuraciones** con la misma validación temporal (T1→T2 y T1+T2→T3), sin usar T4:

Modelo	Valores probados	Mejor configuración	AUC validación de la mejor	AUC validación de la oficial
Regresión logística	C: 0,01; 0,1; 1; 10	C = 0,01	0,7977	0,7976
Random Forest	Profundidad: 8, 13, sin límite × hoja mínima: 10, 35, 100	Profundidad 13, hoja 10	0,7994	0,7982
HistGradientBoosting	Tasa: 0,03; 0,06; 0,1 × hojas: 7, 15, 31	Tasa 0,06, 7 hojas	0,8018	0,8007

Lectura. En las tres familias, la configuración oficial queda a 0,0012 de AUC o menos de la mejor de la grilla: la elección de hiperparámetros no cambia los resultados. Como la grilla se corrió después de la evaluación oficial en T4, las configuraciones de la grilla **no se volvieron a evaluar en T4**, para no usar la prueba dos veces. El ranking entre familias tampoco cambia: HistGradientBoosting queda primero en ambos casos.

Selección del modelo final. Se compararon las tres familias con y sin el perfil del clustering como variable adicional (seis combinaciones más la línea base). Ganó **HistGradientBoosting sin clusters**, con AUC promedio de validación de 0,8007. Se guarda serializado en `output/fase3/mejor_clasificador.joblib`.

7. Resultados y sobreajuste

Desempeño en la prueba (T4, 11.450 adultos, una sola evaluación). Métricas ponderadas; la clase positiva es "sin seguro" y el umbral de decisión es 0,5.

Modelo	AUC-ROC	Exactitud	Exactitud balanceada	Precisión	Exhaustividad	F1	Brier
Línea base (siempre "sin seguro")	0,500	67,9 %	0,500	0,679	1,000	0,809	0,321
Regresión logística	0,784	74,3 %	0,666	0,773	0,879	0,823	0,171
Random Forest	0,789	74,7 %	0,665	0,771	0,892	0,827	0,169
HistGradientBoosting (ganador)	**0,793**	**75,4 %**	**0,687**	**0,788**	**0,874**	**0,828**	**0,167**

Cómo leer la tabla.

- **AUC:** probabilidad de que el modelo asigne más riesgo de no tener seguro a una persona sin seguro que a una con seguro. El ganador acierta en el 79 % de esos pares, frente al 50 % del azar.
- **Exactitud:** sube de 67,9 % a 75,4 %, es decir, 7,5 puntos sobre la línea base.
- **Por qué no basta el F1:** como "sin seguro" es la clase mayoritaria, la línea base ya tiene F1 = 0,809 sin distinguir a nadie. Por eso las métricas decisivas son el AUC y la exactitud balanceada (promedio del acierto en cada clase), que la línea base deja en 0,5.
- **Brier:** error cuadrático de las probabilidades (0 = perfecto). Baja de 0,321 a 0,167: las probabilidades del modelo son mucho más informativas.
- Las tres familias quedan muy cerca entre sí (AUC de 0,784 a 0,793): la señal la aportan las variables, no la complejidad del algoritmo.

Brecha de sobreajuste. AUC ponderado en cada etapa:

Modelo	Entrenamiento (T1 a T3)	Validación temporal	Prueba (T4)	Brecha entrenamiento menos validación
Regresión logística	0,804	0,798	0,784	0,006
Random Forest	0,830	0,798	0,789	0,032
HistGradientBoosting	0,825	0,801	0,793	0,025

Lectura. No hay sobreajuste relevante. Los modelos de árboles rinden unas 3 centésimas más en entrenamiento que en validación, algo esperable por su flexibilidad y controlado con hojas mínimas y regularización. De validación a prueba se pierde alrededor de 0,01 en los tres modelos, coherente con evaluar sobre un trimestre posterior que el modelo no vio.

8. Análisis de errores

Matriz de confusión del modelo ganador en T4 (porcentaje de la población adulta, ponderado):

	Predice "sin seguro"	Predice "con seguro"
No tenía seguro	59,4 % (aciertos)	8,6 % (se escapan)
Tenía seguro	16,0 % (falsas alarmas)	16,1 % (aciertos)

El modelo detecta al **87,4 %** de quienes no tienen seguro, pero reconoce solo a la **mitad (50,1 %)** de quienes sí tienen. El error principal es clasificar como "sin seguro" a personas aseguradas.

Errores por subgrupo (porcentajes ponderados de T4):

Grupo	Sin seguro	Acierto total	Detecta a los sin seguro	Detecta a los con seguro
Rural	82,5 %	85,0 %	96,5 %	30,8 %
Urbana	61,8 %	71,3 %	82,2 %	53,8 %
18 a 29 años	73,7 %	77,0 %	93,1 %	31,9 %
60 años o más	60,9 %	73,3 %	84,2 %	56,2 %
Quintil de ingreso 1	93,3 %	93,3 %	100 %	0,0 %
Quintil de ingreso 3	71,1 %	73,2 %	94,3 %	21,2 %
Quintil de ingreso 5	43,5 %	68,3 %	50,0 %	82,4 %

Los quintiles se calculan sobre la muestra de T4, no son los oficiales del INE. Entre hombres y mujeres el desempeño es parecido (74,2 % y 76,7 % de acierto).

Lectura. El modelo se apoya sobre todo en el ingreso. En los quintiles 1 y 2 clasifica prácticamente a todos como "sin seguro": acierta mucho porque el 93 % y el 85 % no tienen seguro, pero no reconoce a casi ningún asegurado pobre. En el quintil 5 ocurre lo contrario: reconoce bien a los asegurados y se le escapa la mitad de los no asegurados. Lo mismo pasa, en menor medida, en el área rural y entre los jóvenes.

Los casos peor predichos. Se examinó el 1 % de adultos con mayor error (115 personas; error absoluto de 0,913 o más). **Todos son asegurados** a los que el modelo les asignó más de 91 % de probabilidad de no tener seguro:

Característica	Todos los adultos de T4	Peores casos
Años de estudio (media)	9,5	6,2
Ingreso mediano (Gs./mes)	1.577.267	768.044

Característica	Todos los adultos de T4	Peores casos
Rural	44,4 %	71,3 %
Edad media	43,7	45,1
Tipo de seguro	IPS 80 % del total de falsas alarmas	IPS 75,7 %; privado familiar 12,2 %; sanidad militar 6,1 %; policial 3,5 %

Ejemplos: una mujer de 19 años del área rural de Concepción, con ingreso per cápita de 158.066 Gs. y cobertura de Sanidad Policial; una mujer de 53 años y un hombre de 58 del área rural de San Pedro, con el mismo ingreso per cápita (400.833 Gs.), 6 años de estudio y seguro privado familiar.

Por qué falla ahí. Son personas pobres y rurales que tienen seguro por una vía que el modelo no ve: un **empleo formal** (IPS) o ser **familiar de un titular** (seguro familiar, sanidad policial o militar). Las variables del modelo describen el nivel socioeconómico, pero no la relación laboral ni el parentesco con quien aporta. Agregar la categoría ocupacional o el tipo de empleo debería mejorar justamente estos casos, aunque habría que revisar que no introduzca fuga (por ejemplo, el aporte jubilatorio al IPS es casi equivalente a tener IPS).

9. Interpretación del modelo y NBI territorial

Importancia por permutación. Se mide cuánto cae el AUC ponderado en T4 al desordenar cada variable (promedio de 10 repeticiones):

Variable	HistGradientBoosting (ganador)	Regresión logística
Ingreso per cápita	**0,134**	0,095
Años de estudio	0,081	**0,099**
Edad	0,049	0,045
Departamento	0,016	0,016
Área	0,001	0,001
Sexo	0,001	0,000

Dirección de cada efecto. Regresión logística sobre T1 a T3 con errores robustos por UPM; un OR menor que 1 indica menos probabilidad de no tener seguro:

Cambio	OR de no tener seguro	IC 95 %	Lectura
El doble de ingreso per cápita	0,52	0,49 a 0,54	Las odds de no tener seguro se reducen a la mitad
Un año más de estudio	0,85	0,84 a 0,86	15 % menos odds por cada año
10 años más de edad	0,71	0,69 a 0,72	Los mayores tienen más cobertura
Rural (frente a urbana)	1,14	1,03 a 1,27	Algo más de riesgo, ya descontado el ingreso
Mujer (frente a hombre)	1,00	0,95 a 1,05	Sin diferencia
Departamentos (frente a Asunción)	de 1,30 (Central) a 3,18 (Amambay)		Más riesgo fuera de la capital, salvo Presidente Hayes (0,85, no significativo)

Contraste con las fases anteriores. Las variables más influyentes coinciden con lo esperado:

- **Ingreso:** en la Fase 2 el seguro pasaba de 4,8 % a 57,3 % entre quintiles; aquí es la variable más importante.
- **Educación:** H4 mostró su relación con el ingreso (ρ = 0,47); el modelo la usa como segunda variable, y mantiene su efecto aun con el ingreso en el modelo.
- **Área:** H5 y la Fase 1 mostraron diferencias urbano y rural. Aquí su efecto propio es chico, porque buena parte de la diferencia rural ya la explican el ingreso, la educación y el departamento.
- **Sexo:** sin efecto, igual que en la cobertura descriptiva (31,4 % de hombres y 31,7 % de mujeres con seguro).

NBI territorial (contexto, no predictor). Se cruzó el porcentaje de adultos sin seguro de cada departamento (EPHC 2024) con las necesidades básicas insatisfechas de los hogares (INE, Censo 2022), en los 16 departamentos con datos en ambas fuentes:

Dimensión del NBI	ρ de Spearman	p sin corregir
Al menos una NBI	0,39	0,135
Calidad de la vivienda	0,45	0,081

Dimensión del NBI	ρ de Spearman	p sin corregir
Infraestructura sanitaria	0,19	0,481
Acceso a la educación	0,52	0,037
Capacidad de subsistencia	0,53	0,035

Todas las correlaciones son positivas: los departamentos con más NBI tienden a tener más adultos sin seguro. Pero con solo 16 departamentos y 5 comparaciones, **ninguna se sostiene tras la corrección de Benjamini-Hochberg** (el valor ajustado más bajo es 0,094). Además, es una correlación **ecológica**: describe departamentos, no personas, y no permite atribuir el NBI del departamento a cada habitante. Presidente Hayes, por ejemplo, tiene el NBI más alto de los 16 departamentos analizados (58,2 % de hogares con al menos una NBI), pero solo Asunción y Central tienen menos adultos sin seguro que él (60,4 %).

10. Conclusión de la Fase 3

Desempeño frente a la línea base. El modelo ganador (HistGradientBoosting) alcanza en T4 un AUC de 0,793 y una exactitud de 75,4 %, frente a 0,500 y 67,9 % de la línea base. Su exactitud balanceada sube de 0,500 a 0,687. Las tres familias rinden parecido (AUC de 0,784 a 0,793) y no hay sobreajuste relevante.

Variables más predictivas. Ingreso, años de estudio y edad, seguidas del departamento. Coincide con lo esperado por las Fases 1 y 2: la cobertura está fuertemente ligada al nivel socioeconómico. El área aporta poco una vez que se conocen el ingreso y el departamento, y el sexo no aporta.

Cuándo sería utilizable. Para **priorizar a nivel de grupos o territorios** (por ejemplo, dónde concentrar campañas de afiliación o de información sobre cobertura), porque ordena bien a la población por probabilidad de no tener seguro. **No** es utilizable para decidir sobre personas individuales: reconoce solo a la mitad de los asegurados, y entre los más pobres prácticamente a ninguno.

Limitaciones de generalización.

- Un solo año de encuesta; la cobertura puede cambiar con políticas de afiliación o con el mercado laboral.
- Le faltan variables clave, como la formalidad del empleo o el vínculo con un titular del seguro, que explican los peores errores.
- Las métricas ponderadas aproximan la población, pero no reemplazan un análisis completo del diseño muestral (estratos y conglomerados).
- Los perfiles del clustering tienen separación modesta y estabilidad irregular.

- El cruce con el NBI es ecológico, con 16 departamentos y fuentes de años distintos (2022 y 2024).

Riesgos éticos y de sesgo.

- **Estigmatización territorial y socioeconómica:** el modelo asigna alta probabilidad a todo el que es pobre, rural o vive fuera de Asunción. Usado sobre personas, reproduciría un estereotipo y dejaría invisibles a los pobres que sí tienen seguro.
- **Uso indebido:** no debe usarse para negar prestaciones, fijar primas ni seleccionar personas por su probabilidad de no tener seguro.
- **Errores desiguales:** el error es mayor en el área rural, en los jóvenes y en los quintiles bajos; cualquier uso debe revisar el desempeño por subgrupo.
- **Causalidad:** las asociaciones no son causas. Que el ingreso prediga la cobertura no dice cuánto cambiaría la cobertura si cambiara el ingreso.

Respuesta a la pregunta de la Fase 3. La falta de seguro médico se concentra en adultos de bajo ingreso, con poca educación, jóvenes y residentes fuera de Asunción y Central; los perfiles del clustering lo resumen en tres grupos, con entre 49 % y 85 % de adultos sin seguro. Esas características permiten clasificar la condición con una capacidad buena (AUC 0,793), claramente superior a la línea base, aunque con un error sistemático: no reconoce a los asegurados de bajos recursos que acceden al seguro por un empleo formal o por un familiar.

11. Reproducción, uso de asistentes de IA y referencias

Reproducción. Desde la raíz del repositorio (Python 3.10 o superior, semilla 42):

```
pip install -r requirements.txt
pytest -q tests/test_fase3.py
python -m src.fase3.ejecutar
python -m src.fase3.complementos
jupyter nbconvert --to notebook --execute --inplace notebooks/fase3.ipynb
jupyter nbconvert --to html notebooks/fase3.ipynb --output-dir docs --output
fase3.html
```

Uso de asistentes de IA. Se usó Claude (Anthropic) como herramienta de apoyo para: revisar el código y la reproducibilidad y mejorar la redacción de este informe. El grupo ejecutó y verificó los resultados, y tomó las decisiones metodológicas y la interpretación.

Referencias.

- Instituto Nacional de Estadística (INE Paraguay). Encuesta Permanente de Hogares Continua 2024, microdatos REG02 anual y trimestrales.

- Instituto Nacional de Estadística (INE Paraguay). Necesidades Básicas Insatisfechas (NBI) Paraguay 2022, tríptico del Censo 2022.