Informe integrador Grupo 4: seguro médico, salud y cobertura en Paraguay (EPHC 2024)

Carrera: Ingeniería Informática · **Materia:** Data Science · **Proyecto Integrador de Ciencia de Datos**

Informe integrador: Fases 1, 2 y 3

Título: De la enfermedad reciente a la cobertura: seguro médico, salud y perfiles socioeconómicos en Paraguay según la EPHC 2024

Grupo 4

Integrante	C.I.
Kyara Ivanna Popov Araujo	5403389
Zinri Alice Bobadilla Peralta	5306066
Alejandro Sanabria Penayo	5689736

Asunción, 10 de noviembre de 2026

Índice

1. Resumen ejecutivo
2. Problema, pregunta y objetivos
3. Datos y preparación (Fase 1)
4. Fase 1: análisis descriptivo
5. Fase 2: análisis inferencial
6. Del diagnóstico a la reformulación
7. Fase 3: análisis predictivo de la falta de cobertura
8. Conclusión general
9. Limitaciones, riesgos éticos y trabajo futuro
10. Reproducibilidad, uso de asistentes de IA y referencias

1. Resumen ejecutivo

El proyecto partió de una pregunta: **¿se enferman en distinta proporción quienes tienen y quienes no tienen seguro médico en Paraguay?** Con la EPHC 2024 (57.109 personas) la respuesta es que **no, una vez que se compara a personas parecidas**:

- En bruto, reportó enfermedad en los últimos 90 días el 30,44 % de los no asegurados y el 28,99 % de los asegurados: 1,45 puntos porcentuales de diferencia, estadísticamente frágil (p corregido = 0,063).
- A igual edad, sexo, área e ingreso, la diferencia desaparece (OR = 1,007; IC 95 %: 0,95 a 1,07). La diferencia bruta se explica porque los asegurados tienen más ingreso, y en los hogares de más ingreso se reporta menos enfermedad.
- Predecir la enfermedad reciente con las variables de la encuesta resulta débil (AUC de 0,62), y el seguro no aporta a la predicción. Un clustering de perfiles y el cruce con las necesidades básicas insatisfechas (NBI) tampoco encontraron una asociación fuerte con la enfermedad.

El hallazgo que sí fue fuerte en todas las fases es la **desigualdad en la cobertura**: en la muestra, tiene seguro el 4,8 % del quintil más pobre y el 57,3 % del más rico (entre adultos y con ponderación, 6,2 % y 57,7 %). Por eso la Fase 3 se reorientó a la **falta de seguro médico en adultos**:

- El 68,4 % de los adultos no tiene seguro.
- Tres perfiles resumen la desigualdad: 49 %, 79 % y 85 % de adultos sin seguro.
- Un modelo de HistGradientBoosting clasifica la falta de cobertura con AUC 0,793 (frente a 0,5 de la línea base) y exactitud de 75,4 % (frente a 67,9 %). El ingreso, la educación y la edad son las variables más importantes.
- Su error principal: no reconoce a los asegurados de bajos recursos, que acceden al seguro por un empleo formal o por un familiar.

Ninguno de estos resultados es causal: la EPHC es una encuesta observacional.

2. Problema, pregunta y objetivos

Contexto. La Encuesta Permanente de Hogares Continua (EPHC) del Instituto Nacional de Estadística (INE) releva, entre otros temas, si cada persona tiene seguro médico y si en los últimos 90 días estuvo enferma, accidentada o sana. Con esas dos preguntas se puede estudiar si la cobertura se relaciona con el reporte de enfermedad.

Pregunta original (Fases 1 y 2). ¿La proporción de personas que reportaron enfermedad en los últimos 90 días difiere entre quienes poseen y quienes no poseen cobertura de seguro médico en Paraguay, según la EPHC 2024?

Objetivo general original. Analizar la asociación entre la cobertura de seguro médico y la enfermedad reportada en los últimos 90 días en la población representada por la EPHC 2024.

Pregunta reformulada (Fase 3). ¿Qué perfiles sociodemográficos y socioeconómicos se asocian con la falta de seguro médico entre adultos de Paraguay en 2024, y en qué medida esas características permiten clasificar esa condición?

La reformulación la pidió la profesora tras la Fase 2, porque la asociación entre seguro y enfermedad no era lo bastante fuerte. La sección 6 explica el paso de una pregunta a la otra.

Objetivos específicos y fase en que se cumplen.

Objetivo específico	Fase	Estado
Preparar y caracterizar las variables de la EPHC 2024 (calidad, faltantes, recodificación)	1	Cumplido: dataset analítico de 57.109 personas y 25 variables
Describir y comparar la enfermedad reciente entre personas con y sin seguro	1	Cumplido: 29,30 % frente a 27,99 % (ponderado)
Evaluar estadísticamente la asociación entre seguro y enfermedad	2	Cumplido: seis hipótesis contrastadas; el seguro no se asocia al ajustar
Construir y evaluar un modelo predictivo	2 y 3	Cumplido: para enfermedad (AUC 0,62, débil) y, tras la reformulación, para la falta de seguro (AUC 0,793)
Interpretar resultados, patrones, limitaciones e implicancias	1 a 3	Cumplido en cada informe y en este documento

Alcance. Todo el trabajo describe asociaciones en una encuesta transversal y observacional. Ningún resultado se interpreta como causal.

3. Datos y preparación (Fase 1)

Fuente. Base REG02 de la EPHC Anual 2024 (INE), versión con el Factor Revisión 2025: 57.744 personas y 213 variables. La unidad de análisis es la persona. La clave UPM + vivienda + hogar + línea se verificó única en los 57.744 registros. Para la dimensión temporal se usaron los cuatro REG02 trimestrales oficiales de 2024.

Variables seleccionadas. 16 variables originales: identificación (UPM, NVIVI, NHOGA, L02), año, departamento, área, edad (P02), sexo (P06), estado civil (P09), seguro médico (S01A), estado de salud en 90 días (S03), factor de expansión, años de estudio, ingreso per cápita (ipcm) y quintil de ingreso.

Limpieza y transformación (resumen de la bitácora).

Paso	Decisión	Registros afectados	Motivo
1	Normalizar textos vacíos a faltante y convertir factor e ingreso a número (venían con coma decimal)	57.744	Evitar errores de cálculo
2	Años de estudio: código 99 pasa a faltante	Incluidos en el 6,20 % de faltantes	99 no es una cantidad de años
3	Crear `tiene_seguro` (1 si S01A va de 1 a 6; 0 si S01A = 7, "sin seguro")	57.744	Variable binaria de cobertura
4	Crear `enfermedad_reciente` (1 enfermo, 0 sano)	57.744	Variable de resultado de las Fases 1 y 2
5	Excluir accidentados (S03 = 2) y código no válido (S03 = 9)	631 + 4 = 635	Un accidente es un evento distinto de la enfermedad
6	No imputar años de estudio, ingreso ni quintil en esta fase	3.543 / 130 / 130	La imputación se hace dentro del pipeline de modelado
7	Exportar el dataset limpio	57.109 × 25	Transformación reproducible por código

Ponderación. Cada persona representa a un número distinto de habitantes (factor de expansión). Las cifras que buscan describir a la población se presentan ponderadas; los contrastes de la Fase 2 se hicieron sobre la muestra con errores robustos, y los modelos de la Fase 3 usan el factor como peso.

Base de la Fase 3. A partir de la misma REG02 se armó un segundo conjunto: adultos de 18 años o más con respuesta válida de seguro y factor positivo, **40.266 adultos**. Los accidentados vuelven a entrar, porque su exclusión tenía sentido solo para estudiar enfermedad. El trimestre de entrevista se recuperó enlazando cada persona con los REG02 trimestrales por UPM, vivienda, hogar y línea.

Correcciones posteriores. En la Fase 2 se corrigieron dos datos del diccionario de la Fase 1 (factor de expansión entero de 9 a 894, y quintil 1 con 24,05 % de la muestra) y el rango de S01A (1 a 7). Las prevalencias de la Fase 1 eran correctas.

4. Fase 1: análisis descriptivo

Variables numéricas (57.109 personas).

Variable	Media	Mediana	Desv. estándar	P5	P95	Forma
Edad (años)	32,95	30	21,92	3	72	Asimetría positiva leve
Años de estudio	8,17	8	5,03	0	16	Casi simétrica, discreta
Ingreso per cápita (Gs./mes)	1.979.470	1.357.054	2.683.408	373.384	5.213.534	Muy asimétrica (asimetría 11,19)

Por la fuerte asimetría del ingreso, se usan la mediana y los percentiles para describirlo, y en la Fase 3 se transforma con logaritmo.

Cobertura. En la muestra, el 73,53 % no tiene seguro; ponderado, tiene seguro el 30,14 % de la población. El IPS y la categoría "sin seguro" reúnen el 93,25 % de los registros.

Comparación principal: seguro y enfermedad reciente.

Cobertura	Sanos	Enfermos	Enfermedad (muestra)	Enfermedad (ponderada)
Sin seguro	29.211	12.780	30,44 %	29,30 %
Con seguro	10.736	4.382	28,99 %	27,99 %
Diferencia (sin menos con)			1,45 p.p.	1,31 p.p.

La diferencia es chica: alrededor de una persona y media cada 100.

Relaciones adicionales. Asegurados y no asegurados tienen perfiles muy distintos:

Mediana	Con seguro	Sin seguro
Edad	35 años	28 años
Años de estudio	12	6
Ingreso per cápita mensual	2,32 millones de Gs.	1,12 millones de Gs.

La relación entre variables numéricas más marcada fue la de años de estudio e ingreso (Spearman de alrededor de 0,39 en toda la muestra).

Patrones identificados. (1) Diferencia pequeña de enfermedad por cobertura. (2) Perfiles socioeconómicos distintos entre asegurados y no asegurados. (3) Menos enfermedad reportada hacia el quintil de ingreso más alto. (4) Fuerte asimetría y valores extremos del ingreso. (5) Diferencias por sexo y área. (6) Composición urbana y rural estable en 2024 (urbana de 70,93 % en T1 a 71,25 % en T4).

Conclusión de la Fase 1. La pregunta se respondió de forma parcial: hay una diferencia descriptiva pequeña, que no podía leerse aún como significativa ni causal, y que debía revisarse considerando la edad, el ingreso y el área, porque asegurados y no asegurados difieren mucho en esas variables. De ahí surgieron las hipótesis de la Fase 2.

5. Fase 2: análisis inferencial

Hipótesis y método. Se contrastaron seis hipótesis: las cinco preliminares de la Fase 1 y una sexta (H6) que evalúa el seguro controlando otras variables, tal como pedía la conclusión de la Fase 1. Nivel de significancia: 5 %.

Decisiones metodológicas clave.

- **Dependencia entre personas.** Los integrantes de un mismo hogar tienden a enfermarse juntos (correlación intraclase por hogar de 0,31). Por eso las pruebas usan errores estándar robustos por UPM e intervalos por bootstrap que remuestrean UPM completas.
- **Comparaciones múltiples.** Con seis pruebas al 5 %, la probabilidad de al menos un falso positivo sería 26,5 %. La decisión se toma con el valor p robusto corregido por Bonferroni, regla fijada de antemano.
- **Tamaño del efecto.** Con 57.109 personas, diferencias mínimas resultan significativas. Por eso cada prueba informa también el tamaño del efecto.

Resultados.

Hipótesis	Prueba	Resultado	p robusto (Bonferroni)	Tamaño del efecto	Decisión
H1. La enfermedad difiere según el seguro	z de dos proporciones	28,99 % con seguro y 30,44 % sin seguro	0,063	h = −0,032 (trivial)	No se rechaza H0 (evidencia frágil)
H2. La edad difiere entre enfermos y sanos	U de Mann-Whitney	Relación en U: 38,5 % de enfermos en menores de 5, 22,1 % entre 15 y 29, 43,2 % desde los 60	< 0,001	r = 0,063 (trivial)	Se rechaza H0

Hipótesis	Prueba	Resultado	p robusto (Bonferroni)	Tamaño del efecto	Decisión
H3. La enfermedad difiere según quintil de ingreso	Chi-cuadrado (Wald robusto)	El quintil 5 tiene menos enfermos; Q2 frente a Q5: 7,9 p.p.	< 0,001	V = 0,061 (trivial)	Se rechaza H0
H4. Educación e ingreso se asocian positivamente (25 años o más)	ρ de Spearman unilateral	ρ = 0,47 (IC 95 %: 0,457 a 0,483)	< 0,001	Mediano	Se rechaza H0
H5. La enfermedad difiere según el área	z de dos proporciones	31,84 % rural y 28,74 % urbana	< 0,001	h = 0,068 (trivial)	Se rechaza H0
H6. El seguro se asocia con la enfermedad al controlar edad, sexo, área y quintil	Regresión logística	OR ajustado = 1,007 (IC 95 %: 0,951 a 1,065)	1,000	Trivial	No se rechaza H0

El paso clave: cómo cambia el OR del seguro. El OR compara las odds (enfermos por cada sano) de los asegurados con las de los no asegurados. Un OR de 1 significa "sin diferencia".

Modelo	OR del seguro	IC 95 % robusto
Bruto: (4.382 ÷ 10.736) ÷ (12.780 ÷ 29.211) = 0,41 ÷ 0,44	0,93	
M1. + edad	0,886	0,839 a 0,936
M2. + edad, sexo y área	0,910	0,861 a 0,962
M3. + edad, sexo, área y quintil de ingreso	1,007	0,951 a 1,065
M4. M3 + trimestre (sensibilidad)	1,005	0,949 a 1,063

Al agregar el quintil de ingreso, el OR sube de 0,91 a 1,007: los asegurados pertenecen a hogares de más ingreso, y esos hogares reportan menos enfermedad, tengan o no seguro. El 1,007 es e elevado al coeficiente del seguro en M3 (0,0065). En probabilidad, el efecto marginal promedio del seguro es de +0,13 puntos porcentuales (IC 95 %: −1,03 a 1,29).

El mismo modelo muestra qué sí se asocia con la enfermedad: la edad (menores de 5 años, OR = 2,11; 60 o más, OR = 2,69, frente a 15 a 29), ser mujer (OR = 1,27), el quintil 5 (OR = 0,73) y, en menor medida, el área rural (OR = 1,09). El pseudo R^2 del modelo es 0,025: estas variables explican muy poco de quién se enferma.

Conclusión de la Fase 2. H2 a H5 se sostienen con cualquier criterio. H1 es frágil: no alcanza significancia con el criterio declarado (Bonferroni), aunque sí con criterios menos conservadores (Holm, 0,021; Benjamini-Hochberg, 0,013). H6 no se sostiene con ningún criterio. Todas las asociaciones con la enfermedad son triviales en tamaño, mientras que la relación entre nivel socioeconómico y cobertura es muy marcada: en la muestra, tiene seguro el 4,8 % del quintil más pobre y el 57,3 % del más rico.

6. Del diagnóstico a la reformulación

Antes de cambiar la pregunta se intentó, como pidió la devolución de la Fase 2, encontrar una asociación más fuerte con la enfermedad reciente por tres caminos:

Intento	Qué se hizo	Resultado
Estimación base	Línea base, regresión logística y Random Forest para predecir enfermedad reciente	AUC de 0,62 a 0,63, apenas sobre una regla que usa solo la edad (0,605). Quitar el seguro no cambia el desempeño
Clustering de perfiles	MiniBatchKMeans con k = 6 sobre variables demográficas y socioeconómicas	Seis perfiles con enfermedad de 19,7 % a 40,4 %, pero con separación débil (silhouette 0,199). Las diferencias entre perfiles las explica sobre todo la edad
Clasificación con perfiles	Random Forest con el perfil como variable	AUC 0,624 y exactitud 72,61 %, apenas sobre la línea base (72,47 %). Detecta solo al 3,06 % de los enfermos
Zonas y NBI	Cruce de la enfermedad por departamento con las necesidades básicas insatisfechas (Censo 2022)	Correlación entre NBI general y enfermedad negativa y no significativa ($\rho = -0{,}243$; $p = 0{,}365$)

Diagnóstico. La enfermedad reportada en 90 días depende sobre todo de la edad y de factores que la encuesta no mide (enfermedades crónicas, percepción y recuerdo de cada persona). El seguro no aporta. Seguir por ese camino no iba a producir un modelo útil.

Por qué la falta de seguro. El hallazgo fuerte y consistente de las Fases 1 y 2 fue la desigualdad en la cobertura: los asegurados tienen el doble de ingreso mediano y el doble de años de estudio, y la cobertura va de 4,8 % a 57,3 % entre quintiles en la muestra. La

falta de seguro es, además, un problema de acceso a la salud relevante por sí mismo. Por eso la profesora pidió reestructurar el enfoque y la Fase 3 toma como variable objetivo la **ausencia de seguro médico en adultos**.

Qué se conserva. Las Fases 1 y 2 no se reescriben: se mantienen como el diagnóstico que justificó el cambio, y sus hallazgos (relación entre educación e ingreso, diferencias por área, dependencia por hogar y UPM, componente temporal) guían el diseño de la Fase 3. El intento de clustering sobre la enfermedad queda en la rama `fase3-perfiles-nbi-modelos` del repositorio.

7. Fase 3: análisis predictivo de la falta de cobertura

El detalle completo está en el informe de la Fase 3. Aquí se resumen las decisiones y los resultados.

Tarea. Clasificación binaria. Objetivo: `sin_seguro` (1 si S01A = 7). Población: 40.266 adultos. El 72,1 % de la muestra no tiene seguro; ponderado, el 68,4 % de la población adulta, estable entre trimestres (67,9 % a 69,0 %).

Cobertura por quintil de ingreso (adultos, ponderada). Con los quintiles oficiales del INE, tiene seguro el 6,2 % del quintil 1, el 15,0 % del 2, el 28,0 % del 3, el 38,4 % del 4 y el 57,7 % del 5. Si los quintiles se arman dividiendo a los adultos de la muestra en cinco grupos iguales, como en la presentación, los valores son 5,9 % y 58,3 % en los extremos. El gradiente es el mismo.

Variables. Edad, años de estudio, logaritmo del ingreso per cápita, sexo, área y departamento. Imputación por mediana, escalado y codificación dentro de un Pipeline de scikit-learn ajustado solo con entrenamiento. Se excluyen la enfermedad, el tipo de seguro, la UPM y los identificadores para evitar fuga de información.

Partición y validación. Cronológica, como pide la consigna cuando hay componente temporal: trimestres 1 a 3 para desarrollo (28.816 adultos) y trimestre 4 para la prueba final (11.450), evaluada una sola vez. Cada UPM pertenece a un solo trimestre, así que ningún hogar queda repartido. Dentro del desarrollo, validación temporal de origen expansivo: T1→T2 y T1+T2→T3. Modelos y métricas se ponderan con el factor de expansión.

Perfiles por clustering (descriptivo). MiniBatchKMeans sobre edad, educación, ingreso, sexo y área, sin usar el seguro. Se eligió k = 3 (silhouette 0,224).

Perfil (T4)	Sin seguro	Edad media	Años de estudio	Ingreso mediano (Gs./mes)	Rural
A. Más educación e ingreso	49,2 %	38,9	13,8	2.967.491	12,8 %
B. Mayores con poca educación	79,2 %	58,4	5,0	1.149.139	44,1 %

Perfil (T4)	Sin seguro	Edad media	Años de estudio	Ingreso mediano (Gs./mes)	Rural
C. Jóvenes de bajo ingreso	85,0 %	28,1	10,4	1.023.361	40,6 %

Los perfiles se superponen (silhouette modesta), su estabilidad entre semillas es irregular (ARI promedio 0,51) y no mejoran la predicción (AUC de validación 0,8005 con perfil frente a 0,8007 sin él). Se usan para describir, no en el modelo final.

Modelos. Tres familias con el mismo preprocesamiento: regresión logística, Random Forest y HistGradientBoosting. Una búsqueda en grilla de 22 configuraciones con la validación temporal confirmó los hiperparámetros oficiales: en cada familia quedan a 0,0012 de AUC o menos de la mejor configuración.

Resultados en la prueba (T4).

Modelo	AUC	Exactitud	Exactitud balanceada	F1	Brier
Línea base (siempre "sin seguro")	0,500	67,9 %	0,500	0,809	0,321
Regresión logística	0,784	74,3 %	0,666	0,823	0,171
Random Forest	0,789	74,7 %	0,665	0,827	0,169
HistGradientBoosting (ganador)	**0,793**	**75,4 %**	**0,687**	**0,828**	**0,167**

El ganador ordena correctamente al 79 % de los pares formados por una persona sin seguro y una con seguro. No hay sobreajuste relevante: el AUC pasa de 0,825 en entrenamiento a 0,801 en validación y 0,793 en prueba.

Errores. El modelo detecta al 87,4 % de quienes no tienen seguro, pero reconoce solo al 50,1 % de los asegurados. En los quintiles 1 y 2 clasifica a casi todos como "sin seguro". El 1 % peor predicho (115 personas) son asegurados pobres y rurales (71,3 % rurales, ingreso mediano de 768.044 Gs.) que tienen IPS por empleo formal o seguro por un familiar, vías que el modelo no ve.

Qué variables pesan. Por importancia por permutación: ingreso (caída de AUC 0,134), años de estudio (0,081), edad (0,049) y departamento (0,016); área y sexo casi no aportan. En la regresión logística con errores robustos por UPM, duplicar el ingreso reduce a la mitad las odds de no tener seguro (OR 0,52), cada año de estudio las reduce 15 % (OR 0,85) y cada 10 años de edad, 29 % (OR 0,71). Fuera de Asunción el riesgo es mayor (OR de 1,30 en Central a 3,18 en Amambay).

NBI territorial. En los 16 departamentos con datos en ambas fuentes, los que tienen más necesidades básicas insatisfechas (INE, Censo 2022) tienden a tener más adultos sin seguro: todas las correlaciones son positivas (ρ de 0,19 a 0,53). Pero ninguna se sostiene

tras la corrección por comparaciones múltiples, y es una correlación ecológica: describe departamentos, no personas.

8. Conclusión general

Respuesta a la pregunta original. ¿Difiere la proporción de enfermedad reciente entre personas con y sin seguro? **Solo en bruto, y muy poco.** Sin seguro reportó enfermedad el 30,44 % y con seguro el 28,99 % (ponderado: 29,30 % y 27,99 %). Esa diferencia de alrededor de 1,4 puntos es frágil (no supera la corrección de Bonferroni) y desaparece al comparar personas de igual edad, sexo, área y quintil de ingreso (OR ajustado 1,007; IC 95 %: 0,95 a 1,07). La diferencia bruta no se debe al seguro, sino a que los asegurados viven en hogares de más ingreso, donde se reporta menos enfermedad. Los datos no muestran que tener seguro se asocie con enfermarse más o menos.

Respuesta a la pregunta reformulada. ¿Qué perfiles se asocian con la falta de seguro y en qué medida permiten clasificarla? La falta de seguro se concentra en adultos de bajo ingreso, con poca educación, jóvenes y residentes fuera de Asunción y Central. Tres perfiles lo resumen, con 49 %, 79 % y 85 % de adultos sin seguro. Con esas características, un modelo HistGradientBoosting clasifica la condición con capacidad buena (AUC 0,793 y exactitud 75,4 %, frente a 0,500 y 67,9 % de la línea base), con un error sistemático: no reconoce a los asegurados de bajos recursos que acceden al seguro por un empleo formal o por un familiar.

Fase	Qué se preguntó	Qué se encontró	Qué dejó para la siguiente
1	¿Difiere la enfermedad según el seguro? (descriptivo)	Diferencia pequeña (1,31 p.p.); asegurados con más ingreso, educación y edad	Revisar la diferencia controlando ingreso, edad y área
2	¿Es significativa y se mantiene al ajustar? (inferencial)	Frágil en bruto, nula al ajustar; la cobertura sí depende mucho del ingreso	Enfermedad difícil de predecir; desigualdad de cobertura como hallazgo fuerte
Transición	¿Hay una asociación más fuerte con perfiles, zonas o NBI?	No: AUC 0,62 y perfiles explicados por la edad	Reformular hacia la falta de seguro
3	¿Quién no tiene seguro y se puede clasificar? (predictivo)	Ingreso, educación y edad explican la falta de seguro; AUC 0,793	Agregar formalidad del empleo y vínculo con el titular

Estado final de las hipótesis.

Hipótesis	Estado	En lenguaje simple
H1. Enfermedad difiere según seguro	Frágil	Hay una diferencia mínima que no resiste el criterio más estricto
H2. Edad difiere según enfermedad	Se sostiene	Niños chicos y mayores reportan más enfermedad
H3. Enfermedad difiere según quintil	Se sostiene	El quintil más rico reporta menos enfermedad
H4. Educación e ingreso se asocian	Se sostiene	Más años de estudio, más ingreso (ρ = 0,47); en la Fase 3 ambas predicen la cobertura
H5. Enfermedad difiere según área	Se sostiene	En el área rural se reporta algo más de enfermedad
H6. Seguro asociado al ajustar	No se sostiene	A igual perfil, el seguro no cambia el riesgo de enfermar

Una diferencia bruta puede deberse a quiénes forman cada grupo y no a la variable que se estudia. Controlar el ingreso cambió la respuesta de la pregunta original, y al mismo tiempo mostró dónde estaba la señal fuerte: en la desigualdad de la cobertura.

9. Limitaciones, riesgos éticos y trabajo futuro

Limitaciones.

- **Diseño observacional y transversal.** Ningún resultado es causal. Que el ingreso prediga la cobertura no dice cuánto cambiaría la cobertura si cambiara el ingreso.
- **Medición.** La enfermedad es autorreportada con un recuerdo de 90 días, y en los niños la reporta un adulto.
- **Diseño muestral.** Se usaron el factor de expansión y errores robustos por UPM, pero no se dispone de los estratos, así que los errores estándar son aproximados.
- **Un solo año.** La cobertura puede cambiar con políticas de afiliación o con el mercado laboral, y no puede separarse la estación de otros hechos de 2024.
- **Variables ausentes.** Faltan las enfermedades crónicas (para la enfermedad) y la formalidad del empleo o el vínculo con el titular (para la cobertura); esta última explica los peores errores del modelo.

- **Clustering y NBI.** Los perfiles tienen separación modesta y estabilidad irregular. El cruce con el NBI es ecológico, con 16 departamentos y fuentes de años distintos (2022 y 2024).

Riesgos éticos y de sesgo.

- **Estigmatización.** El modelo asigna alta probabilidad de no tener seguro a todo el que es pobre, rural o vive fuera de Asunción. Aplicado a personas, reproduciría un estereotipo y dejaría invisibles a los pobres que sí tienen seguro.
- **Errores desiguales.** El error es mayor en el área rural, en los jóvenes y en los quintiles bajos; cualquier uso debe revisar el desempeño por subgrupo.
- **Privacidad.** Se trabajó con microdatos anónimos publicados por el INE; los ejemplos de casos se describen sin datos que identifiquen a nadie.

Trabajo futuro.

- Agregar la categoría ocupacional y el tipo de empleo, cuidando la fuga (el aporte jubilatorio al IPS es casi equivalente a tener IPS).
- Repetir el análisis con la EPHC de otros años para medir la estabilidad del modelo.
- Incorporar los estratos del diseño muestral si el INE los publica.
- Ajustar el umbral de decisión según el uso (por ejemplo, para no dejar fuera a los asegurados de bajos recursos).

10. Reproducibilidad, uso de asistentes de IA y referencias

Repositorio. `https://github.com/alesanabriap/proyecto-data-science-grupo4`. Python 3.10 o superior, semilla 42 en la Fase 3 y semilla fija en `src/fase2/datos.py`.

Fase	Cómo se reproduce	Salidas
1	Ejecutar `notebooks/fase1.ipynb`	`data/processed/ephc_salud_2024_limpio.csv`, `output/graficos/`, `docs/fase1_FINAL.html`
2	Ejecutar las tres partes de `notebooks/fase2_parte*.ipynb`, luego `python -m src.fase2.unir_notebooks`	`output/fase2/`, `docs/fase2.html`
3	`pytest -q tests/test_fase3.py`, `python -m src.fase3.ejecutar`, `python -m src.fase3.complementos` y ejecutar `notebooks/fase3.ipynb`	`output/fase3/`, `output/fase3/complementos/`, `docs/fase3.html`, `mejor_clasificador.joblib`

Uso de asistentes de IA. Se usó Claude (Anthropic) como herramienta de apoyo: en la Fase 1, para depurar código, consultar sintaxis y corregir redacción; en la Fase 2, para proponer pruebas y verificaciones de supuestos, redactar el borrador del informe y

verificar cifras; en la Fase 3, para revisar el código y la reproducibilidad, programar los análisis complementarios y mejorar la redacción de los informes.

- Instituto Nacional de Estadística (INE Paraguay). Encuesta Permanente de Hogares Continua 2024, microdatos REG02 anual (Factor Revisión 2025) y trimestrales. https://www.ine.gov.py/microdato/
- Instituto Nacional de Estadística (INE Paraguay). Necesidades Básicas Insatisfechas (NBI) Paraguay 2022, Censo 2022.
- Materiales de clase de Data Science y consigna del Proyecto Integrador de Ciencia de Datos en tres fases.